

CHƯƠNG 2.

Mô hình lập trình MapReduce và Hadoop

Nội dung

- ❖ Giới thiệu về Hadoop
- ❖ Mô hình MapReduce
- ❖ Môi trường lập trình Hadoop MapReduce
- ❖ Lập trình bài toán WordCount

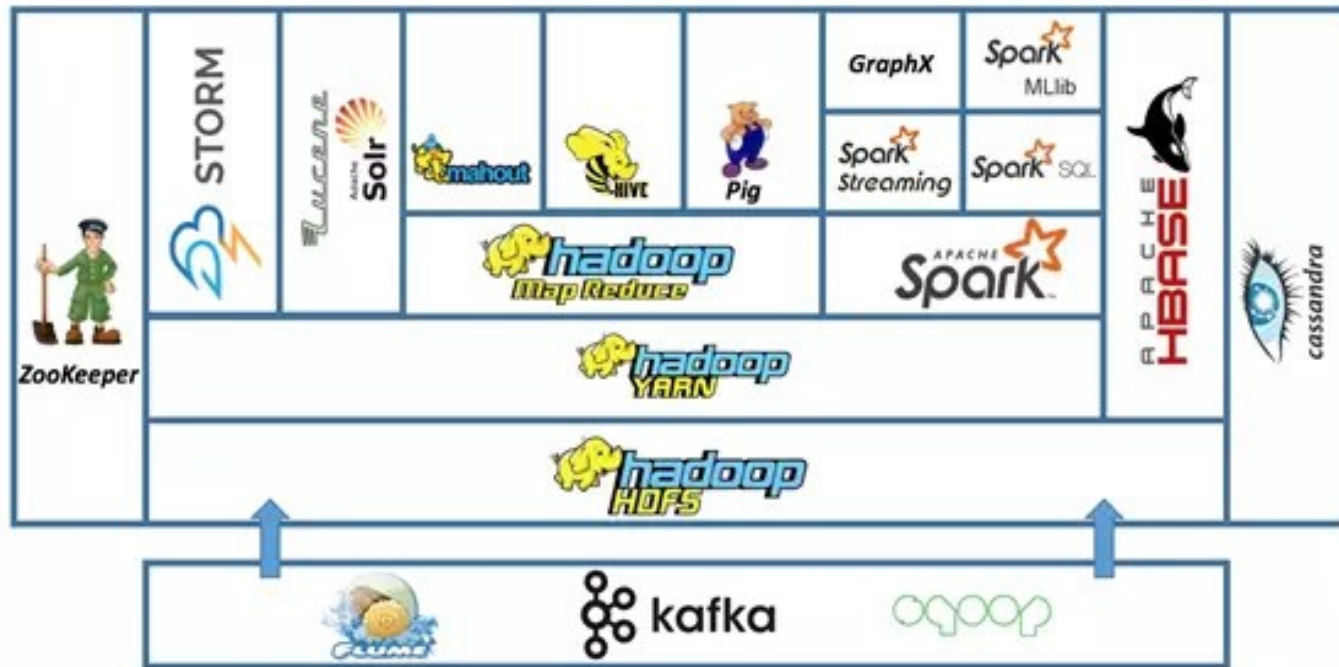
Tổng quan về Hadoop

❖ Hadoop là gì?

- **Hadoop** là một công nghệ phân tán và mã nguồn mở được sử dụng phổ biến để xử lý và lưu trữ khối dữ liệu lớn trên các cụm máy tính phân tán, được thiết kế để xử lý và lưu trữ dữ liệu lớn một cách hiệu quả.
- **Hadoop** được tạo ra bởi **Doug Cutting** và **Mike Cafarella** và năm *2005*, và được phát triển bởi **Apache Software Foundation** dựa trên công nghệ **Google File System** và **MapReduce**.

Tổng quan về Hadoop

❖ Hệ sinh thái Hadoop



Tổng quan về Hadoop

❖ Hệ sinh thái Hadoop

- **Hadoop** sử dụng mô hình phân tán để lưu trữ và xử lý dữ liệu trên các máy tính thông thường.
- **Hadoop** phân chia dữ liệu thành các khối và lưu chúng trên nhiều máy tính, giúp tăng khả năng mở rộng, độ tin cậy và hiệu năng.
- **Hadoop** phân tán dữ liệu trên nhiều nút máy tính và xử lý nó *song song* trên các nút, giúp giảm thời gian xử lý và tăng hiệu suất

Tổng quan về Hadoop

❖ Hệ sinh thái Hadoop

- **Hadoop** được xây dựng dựa trên ba phần chính là **Hadoop Distributed FileSystem (HDFS)**, **YARN** và **MapReduce**.
- **Hadoop** phân chia dữ liệu thành các khối và lưu chúng trên nhiều máy tính, giúp tăng khả năng mở rộng, độ tin cậy và hiệu năng.
- **Hadoop** phân tán dữ liệu trên nhiều nút máy tính và xử lý nó *song song* trên các nút, giúp giảm thời gian xử lý và tăng hiệu suất

Tổng quan về Hadoop

❖ Hadoop là gì?

- **Hadoop** là một công nghệ phân tán và mã nguồn mở được sử dụng phổ biến để xử lý và lưu trữ khối dữ liệu lớn trên các cụm máy tính phân tán, được thiết kế để xử lý và lưu trữ dữ liệu lớn một cách hiệu quả.
- **Hadoop** được tạo ra bởi **Doug Cutting** và **Mike Cafarella** và năm *2005*, và được phát triển bởi **Apache Software Foundation** dựa trên công nghệ **Google File System** và **MapReduce**.

Mô hình MapReduce

- ❖ Lịch sử ra đời MapReduce
- ❖ MapReduce là gì?
- ❖ Quản lý thực thi công việc
- ❖ Thực hiện công việc trên MapReduce
- ❖ Ví dụ: Bài toán đếm từ
- ❖ Hàm map, reduce
- ❖ Ưu điểm của mô hình MapReduce
- ❖ Kiến trúc các thành phần
- ❖ Cơ chế hoạt động
- ❖ Ứng dụng của MapReduce

Lịch sử ra đời MapReduce

- ❖ Trước khi Google công bố mô hình MapReduce
 - ❖ Bùng nổ của dữ liệu (hàng petabyte)
 - ❖ Nhu cầu thực hiện xử lý các nghiệp vụ trên lượng dữ liệu khổng lồ là thách thức lớn lúc bấy giờ
 - ❖ Doanh nghiệp đang gặp vấn đề tương tự khi muốn tìm một giải pháp tốn ít chi phí và hiệu năng thể hiện cao
- ❖ Trong khi nghiên cứu, một nhóm nhân viên của Google đã khám phá ra một ý tưởng để giải quyết nhu cầu xử lý lượng dữ liệu lớn là việc cần phải có hệ thống nhiều các máy tính và cần có các thao tác để xử lý đồng bộ trên hệ thống đó
- ❖ Nhóm nghiên cứu đã xác định được 2 thao tác cơ bản là Map và Reduce, nó được lấy cảm hứng từ phong cách lập trình hàm (Functional Programming)

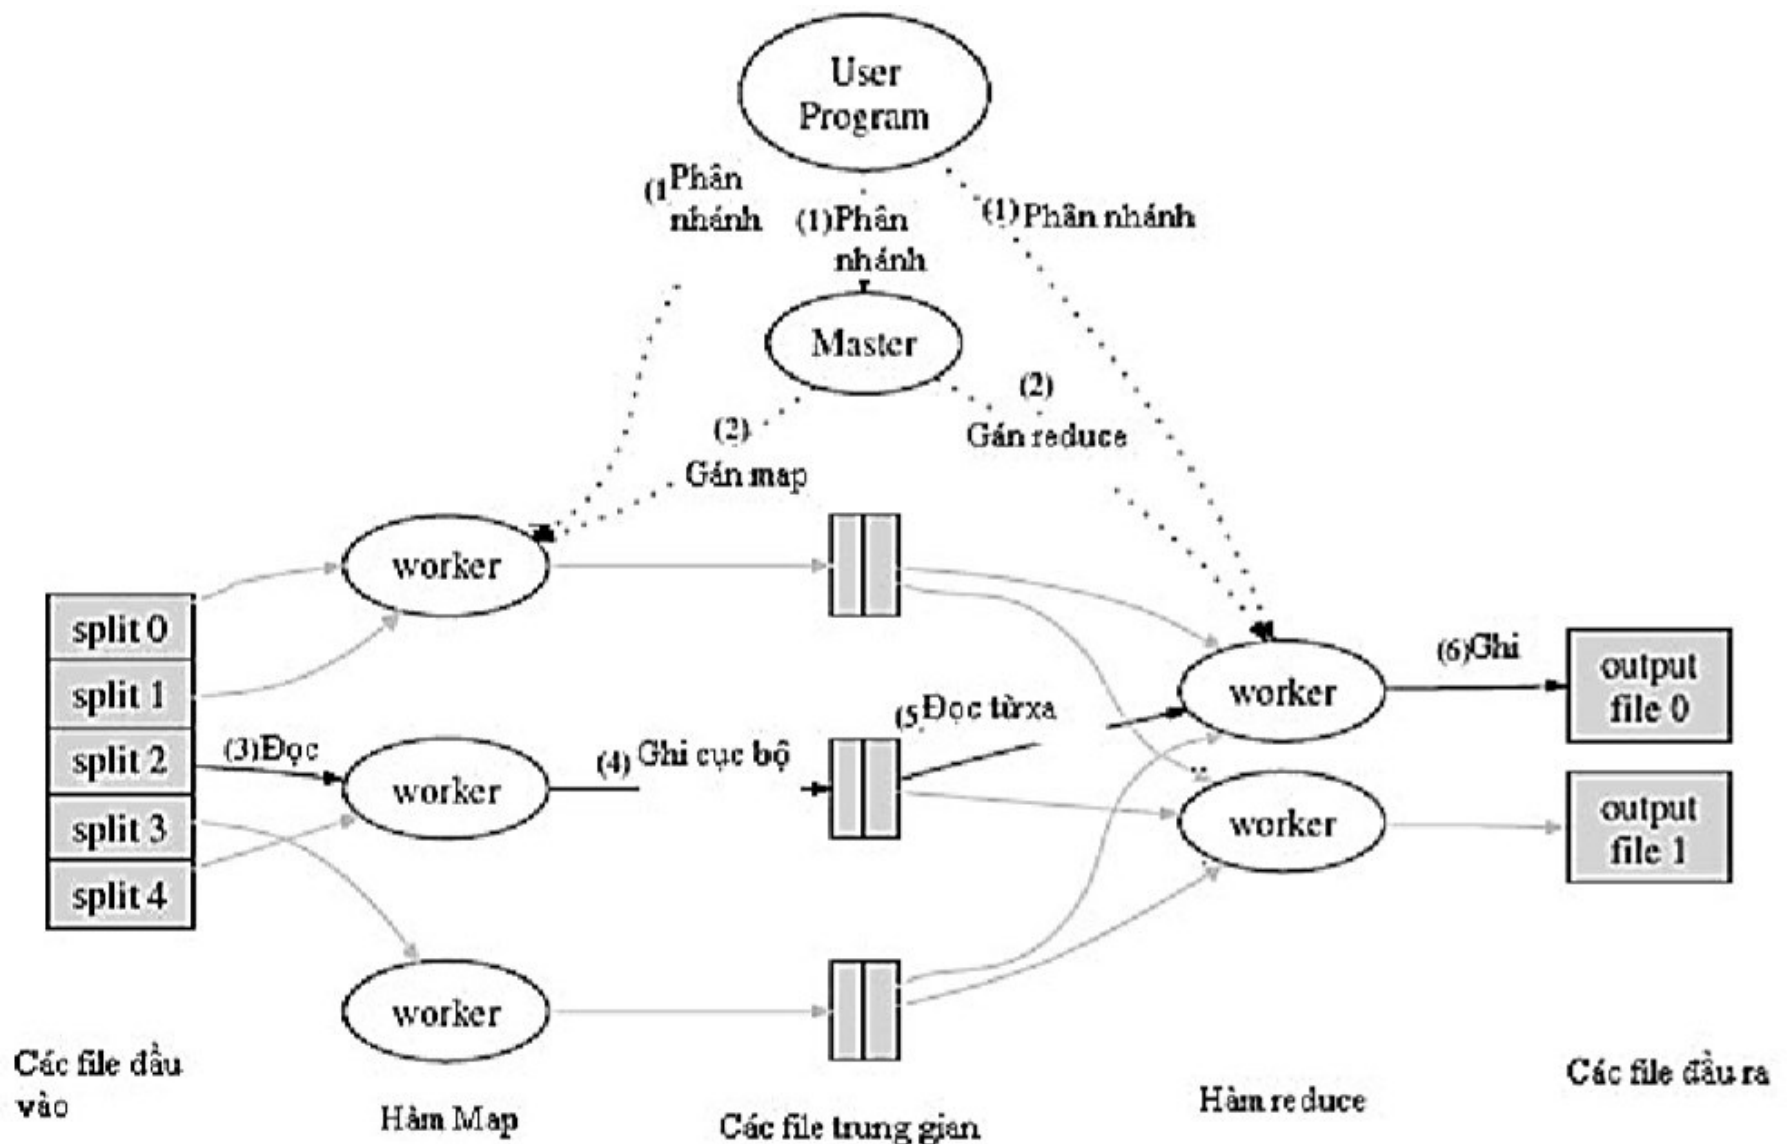
MapReduce là gì?

- ❖ Với ý tưởng trên, Google phát triển thành công mô hình MapReduce:
 - ❖ Là mô hình dùng cho xử lý tính toán song song và phân tán trên hệ thống phân tán
 - ❖ B1: Phân rã từ nghiệp vụ chính (do người dùng muốn thể hiện) thành các công việc con để chia từng công việc con này về các máy tính trong hệ thống thực hiện xử lý một cách song song
 - ❖ B2: Thu thập lại các kết quả
- ❖ Theo tài liệu “MapReduce: Simplified Data Processing on Large Clusters” của Google: “MapReduce là mô hình lập trình và thực thi song song các xử lý và phát sinh các tập dữ liệu lớn”
- ❖ Với mô hình này, các doanh nghiệp đã cải thiện được đáng kể về hiệu suất xử lý tính toán trên dữ liệu lớn, chi phí đầu tư rẻ và độ an toàn cao

Quản lý thực thi công việc

- ❖ Hệ thống định nghĩa:
 - ❖ Một máy trong hệ thống đóng vai trò là master
 - ❖ Các máy còn lại đóng vai trò các worker (dựa trên kiến trúc Master-Slave)
- ❖ Master chịu trách nhiệm quản lý toàn bộ quá trình thực thi công việc trên hệ thống như
 - ❖ Tiếp nhận công việc
 - ❖ Phân rã công việc thành công việc con
 - ❖ Phân công các công việc con cho các worker
- ❖ Worker chỉ làm nhiệm vụ thực hiện công việc con được giao (thực hiện hàm map hoặc hàm reduce)

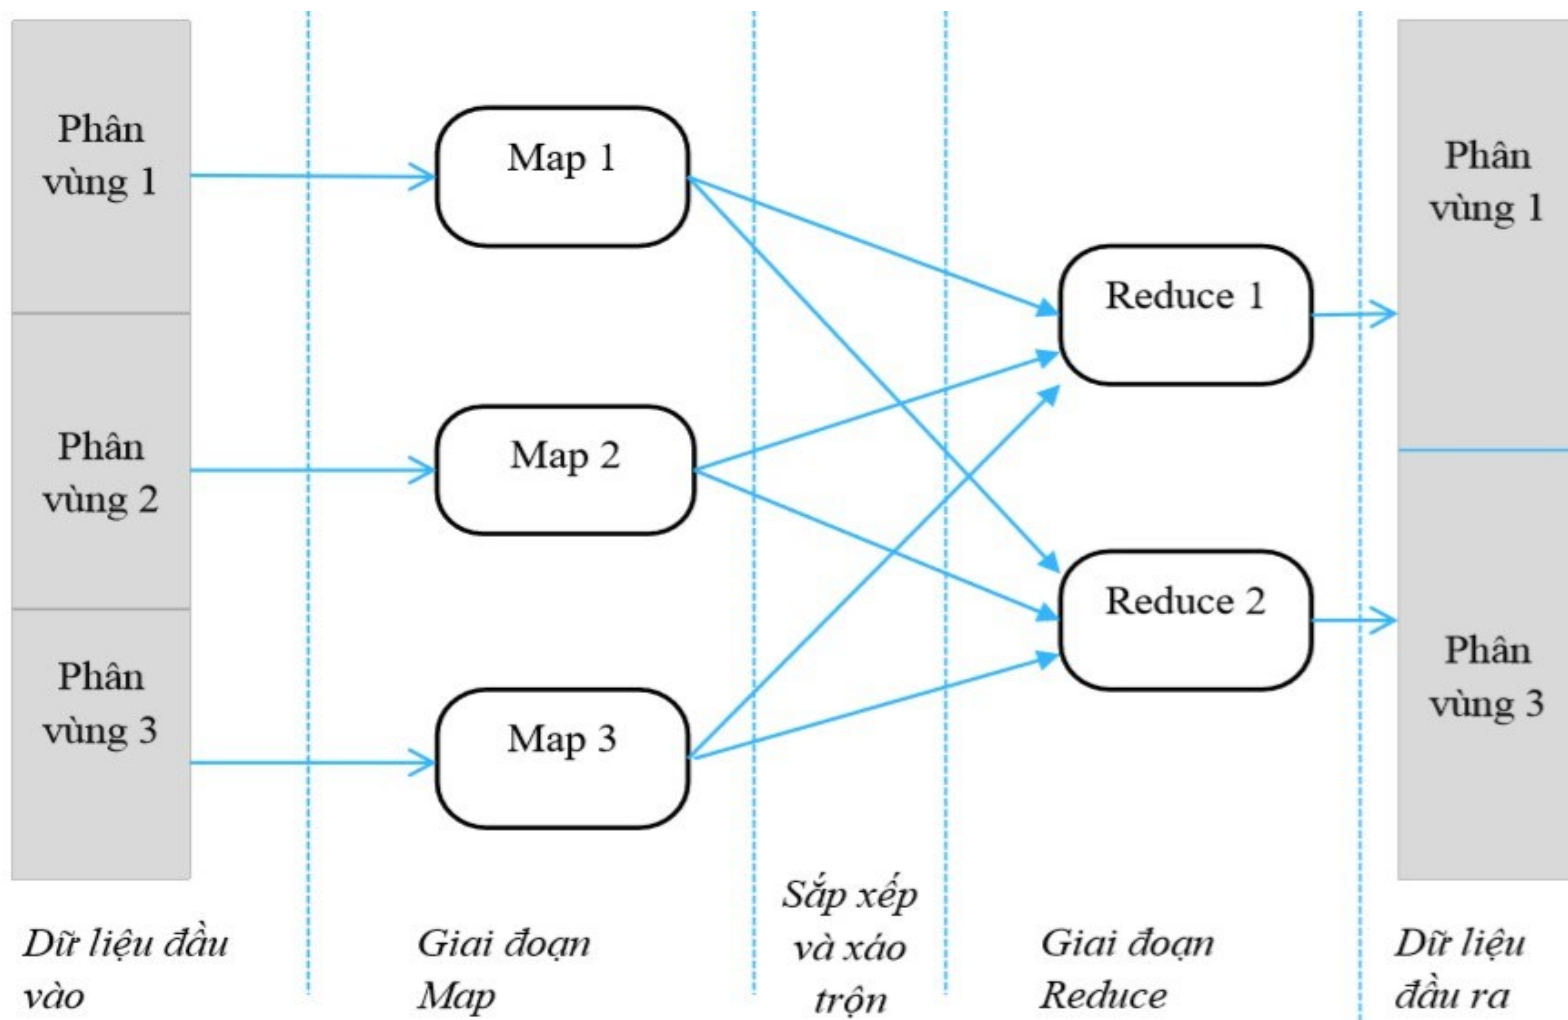
Quản lý thực thi công việc



Thực hiện công việc trên MapReduce

- ❖ Quy trình thực hiện công việc
 - ❖ B1: Chia dữ liệu đầu vào thành các mảnh dữ liệu
 - ❖ B2: Thực hiện công việc **Map** trên từng mảnh dữ liệu đầu vào
- ❖ => Xử lý song song các mảnh dữ liệu trên nhiều máy tính trong cụm
 - ❖ B3: Tổng hợp kết quả trung gian (Sắp xếp, trộn)
 - ❖ B4: Sau khi tất cả công việc Map hoàn thành, thực hiện công việc **Reduce** trên từng mảnh dữ liệu trung gian
- ❖ => Thực hiện song song các mảnh dữ liệu trung gian trên nhiều máy tính trong cụm
 - ❖ B5: Tổng hợp kết quả hàm Reduce để cho kết quả cuối cùng

Thực hiện công việc trên MapReduce



Ví dụ: Bài toán đếm từ

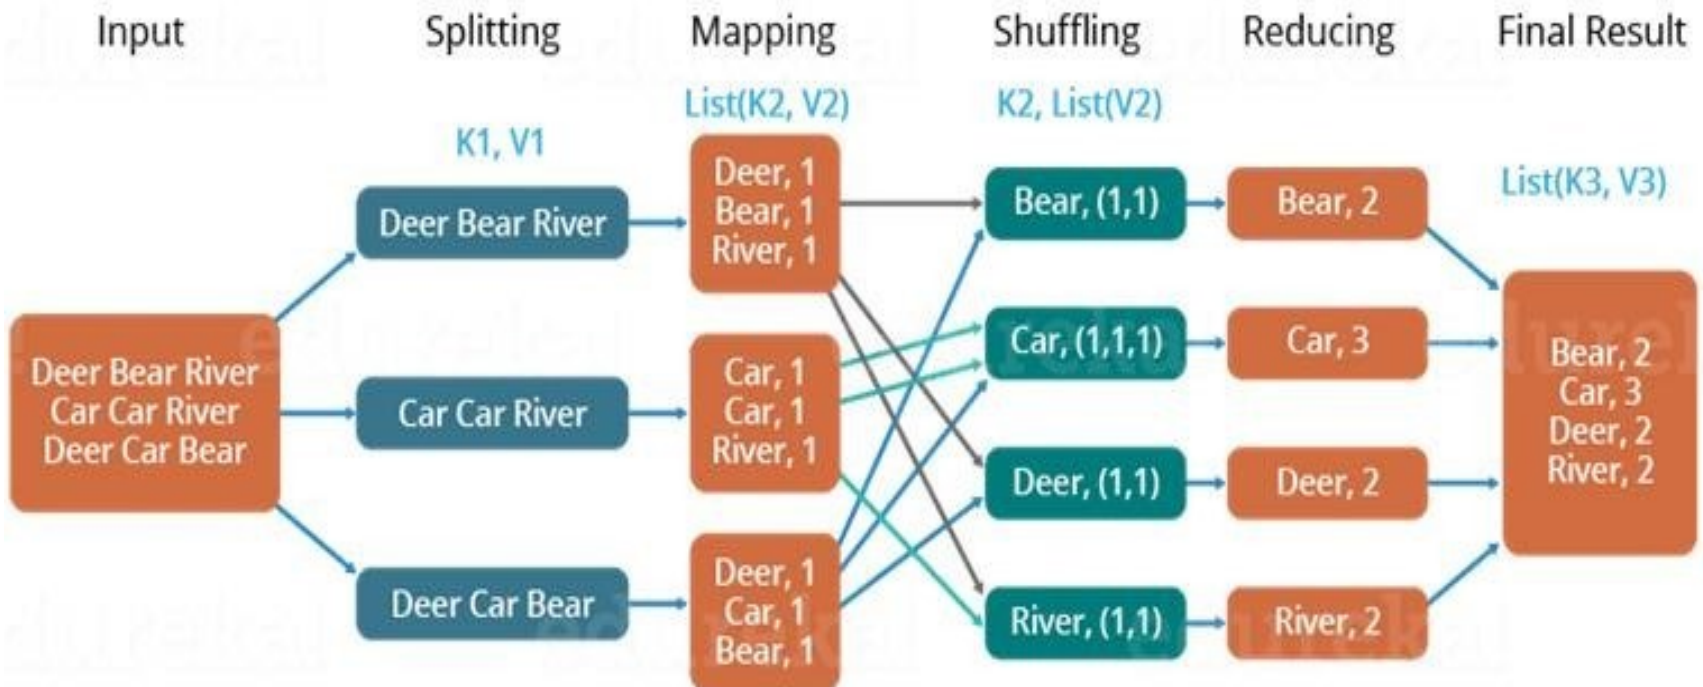
- ❖ File text example.txt có nội dung như sau:
 - ❖ Dear, Bear, River, Car, Car, River, Deer, Car, Bear
- ❖ Nhiệm vụ: đếm tần xuất các từ trong example.txt sử dụng MapReduce
- ❖ Ý tưởng: tìm các từ duy nhất và đếm số lần xuất hiện của các từ này
- ❖ Quy trình thực hiện:
 - ❖ B1-Splitting: Giả sử chia đầu vào 3 phần
 - ❖ P1: Dear, Bear, River
 - ❖ P2: Car, Car, River
 - ❖ P3: Deer, Car, Bear
 - ❖ B2-Mapping: Với mỗi phần, duyệt từng từ, gán giá trị 1 cho mỗi từ (lý do: ko tính lặp lại, mỗi từ xuất hiện 1 lần) để thu được list (từ, 1)
 - ❖ Dear, Bear, River -> (Dear,1), (Bear,1), (River,1)
 - ❖ Car, Car, River -> (Car,1), (Car,1), (River,1)
 - ❖ Dear, Car, Bear -> (Dear,1), (Car,1), (Bear,1)

Ví dụ: Bài toán đếm từ

- ❖ Quy trình thực hiện (tiếp):
 - ❖ B3: Shorting & Shuffling: Nhóm các giá trị cùng một từ, kết quả thu được
 - ❖ Bear, (1,1); Car, (1,1,1); Dear, (1,1); River, (1,1)
 - ❖ B4: Reducing: Tính tổng các giá trị cùng một từ
 - ❖ Bear, (1,1) -> (Bear, 2)
 - ❖ Car, (1,1,1) -> (Car,3)
 - ❖ Dear, (1,1) -> (Dear,2)
 - ❖ River, (1,1) -> (River,2)
 - ❖ B5: Tổng hợp kết quả Reduce được kết quả cuối cùng
 - ❖ (Bear, 2); (Car,3); (Dear,2); (River,2)

Ví dụ: Bài toán đếm từ

❖ Quy trình đếm từ dựa trên mô hình MapReduce



Hàm map, reduce

- ❖ MapReduce dùng hai thao tác chính cho việc thực thi công việc là hàm Map và hàm Reduce
 - ❖ Hàm Map tiếp nhận mảnh dữ liệu input, rút trích thông tin cần thiết các từng phần tử (ví dụ: lọc dữ liệu, hoặc trích dữ liệu) tạo kết quả trung gian
 - ❖ Hệ thống thực hiện một bước trung gian để trộn và sắp xếp lại kết quả
 - ❖ Hàm Reduce tổng hợp kết quả trung gian, tính toán để cho kết quả cuối cùng
- ❖ Hàm Map và Reduce được xem là phần xử lý quan trọng nhất trong mô hình MapReduce, do người dùng định nghĩa tùy theo nhu cầu sử dụng
- ❖ Giai đoạn reduce chỉ bắt đầu khi giai đoạn map kết thúc

Hàm map, reduce

- ❖ MapReduce định nghĩa dữ liệu (cấu trúc và không cấu trúc) dưới dạng cặp khóa/giá trị (key/value)
 - ❖ Ví dụ: key có thể là tên của tập tin (file) và value nội dung của tập tin, hoặc key là địa chỉ URL và value là nội dung của URL...
 - ❖ Việc định nghĩa dữ liệu thành cặp key/value này linh hoạt hơn các bảng dữ liệu quan hệ 2 chiều truyền thống (khóa chính - khóa ngoại)
- ❖ Hàm map và reduce làm việc với khối dữ liệu dạng này
- ❖ Hàm map:
 - ❖ Input: một cặp (keyIn, valIn)
 - ❖ Output: danh sách các cặp (keyInt, valInt) trung gian (Intermediate)
 - ❖ Biểu diễn hình thức: `map (keyIn, valIn) -> list (keyInt, valInt)`
- ❖ Hàm reduce:
 - ❖ Input: một cặp (keyInt, list(valInt))
 - ❖ Output: danh sách các cặp (keyOut, valOut)
 - ❖ Biểu diễn hình thức: `reduce (keyInt, list(valInt)) -> list (keyOut, valOut)`

Ưu điểm của mô hình MapReduce

- ❖ Xây dựng từ mô hình lập trình hàm và lập trình song song
- ❖ Giúp cải thiện tốc độ tính toán trên tập dữ liệu lớn bằng cách tăng tốc độ đọc ghi và xử lý dữ liệu
- ❖ Có thể áp dụng hiệu quả có nhiều bản toán.
- ❖ Ẩn đi các chi tiết cài đặt và quản lý như:
 - ❖ Quản lý tiến trình song song và phân tán
 - ❖ Quản lý, sắp xếp lịch trình truy xuất I/O
 - ❖ Theo dõi trạng thái dữ liệu
 - ❖ Quản lý số lượng lớn dữ liệu có quan hệ phụ thuộc nhau
 - ❖ Xử lý lỗi
 - ❖ Cung cấp mô hình lập trình đơn giản => Người dùng quan tâm chủ yếu đến hàm map, reduce
- ❖ ...

Kiến trúc các thành phần

- ❖ Xét một cách trừu tượng, Hadoop MapReduce gồm 4 thành phần chính riêng biệt
 - ❖ **Client Program:** Chương trình HadoopMapReduce client sử dụng để chạy một MapReduce Job
 - ❖ **JobTracker:**
 - ❖ Tiếp nhận job và đảm nhận vai trò điều phối job này
 - ❖ Có vai trò như bộ não của Hadoop MapReduce
 - ❖ Chia nhỏ job thành các task
 - ❖ Lập lịch phân công các task (map task, reduce task) này đến các tasktracker để thực hiện
 - ❖ Có cấu trúc dữ liệu riêng để sử dụng cho mục đích lưu trữ: lưu lại tiến độ tổng thể của từng job, lưu lại trạng thái của các TaskTracker để thuận tiện cho thao tác lên lịch phân công task, lưu lại địa chỉ lưu trữ của các output của các TaskTracker thực hiện maptask trả về

Kiến trúc các thành phần

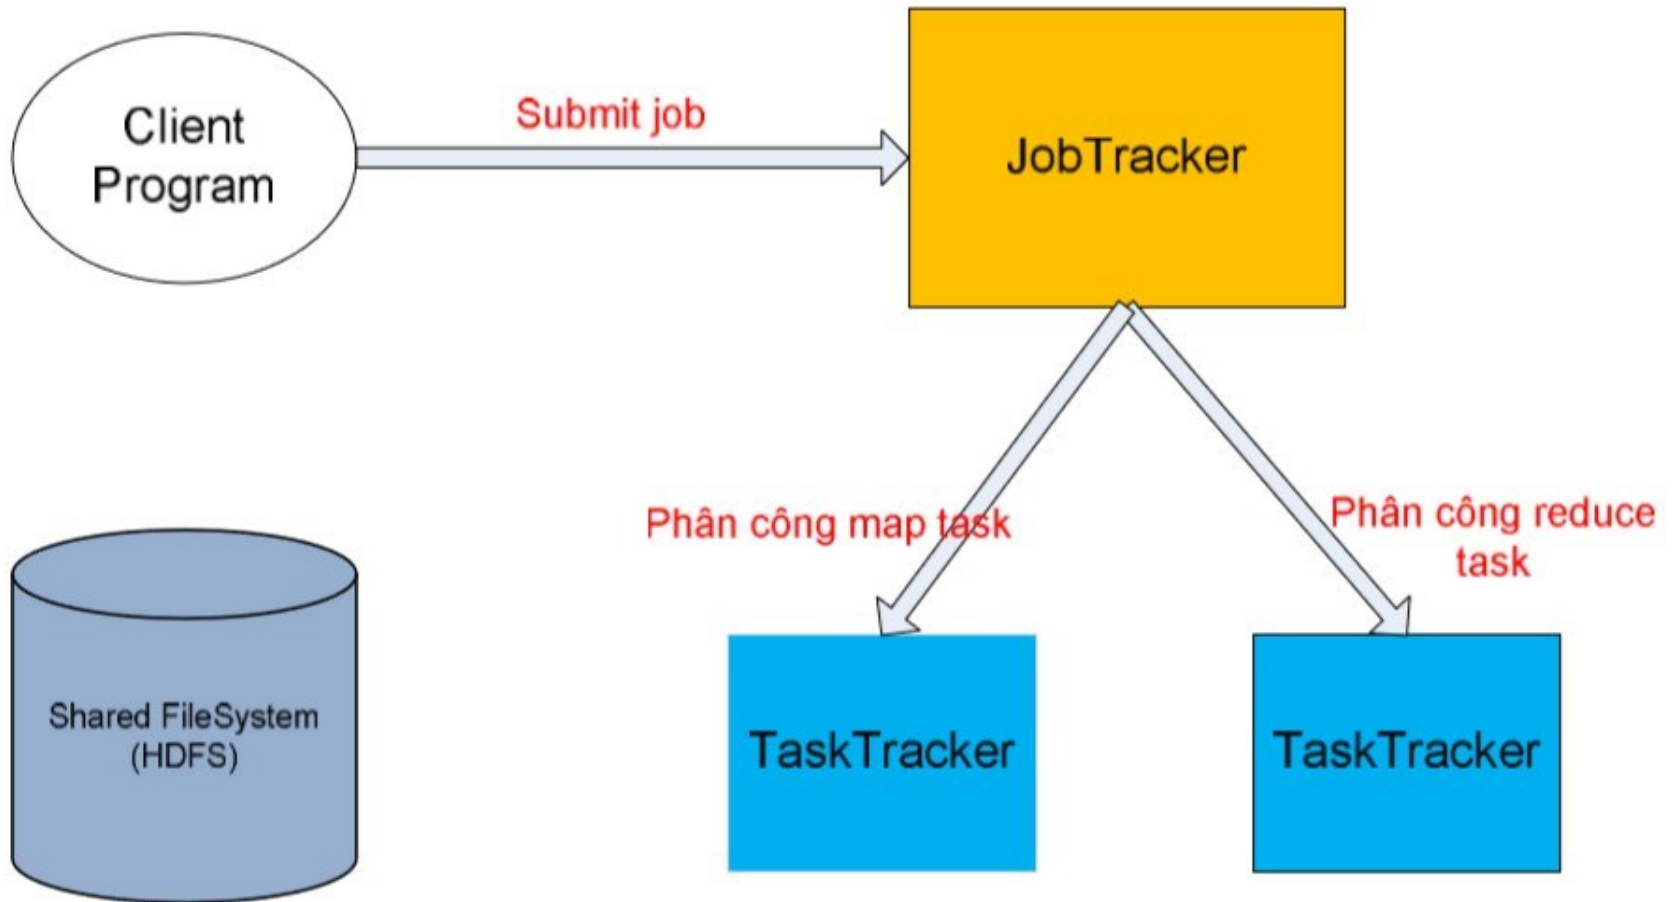
❖ TaskTracker:

- ❖ Tiếp nhận maptask hay reducetask từ JobTracker để sau đó thực hiện
- ❖ Để giữ liên lạc với JobTracker, Hadoop Mapreduce cung cấp cơ chế gửi heartbeat từ TaskTracker đến JobTracker cho các nhu cầu như thông báo tiến độ của task do TaskTracker đó thực hiện, thông báo trạng thái hiện hành của nó (idle, in-progress, completed)

❖ HDFS:

- ❖ Hệ thống file phân tán được dùng cho việc chia sẻ các file dùng trong cả quá trình xử lý một job giữa các thành phần trên với nhau

Kiến trúc các thành phần



Cơ chế hoạt động

- ❖ Submit Job và chuẩn bị dữ liệu
- ❖ Quản lý Job và chia task
- ❖ Liên lạc giữa JobTracker và TaskTracker
- ❖ Làm việc ở MapTaskTracker
- ❖ Làm việc ở ReduceTaskTracker

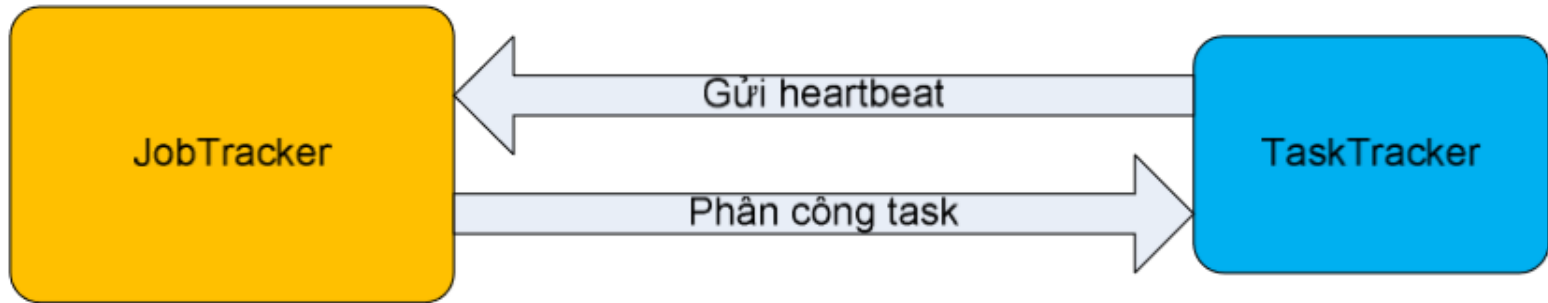
Submit Job và chuẩn bị dữ liệu

- ❖ Client gửi yêu cầu thực hiện job và kèm theo dữ liệu input tới JobTracker
- ❖ JobTracker thông báo cho client tình trạng tiếp nhận job
- ❖ Nếu tình trạng tiếp nhận hợp lệ, client tiến hành phân rã input này thành các split và ghi vào HDFS
- ❖ Client gửi thông báo sẵn sàng để JobTracker biết việc chuẩn bị dữ liệu đã thành công và tiến hành thực hiện job

Quản lý Job và chia Task

- ❖ Khi nhận được thông báo sẵn sàng từ client, JobTracker đưa job này vào một danh sách lưu các Job mà các client yêu cầu thực hiện
- ❖ Tại một thời điểm JobTracker chỉ thực hiện một job
- ❖ Sau khi một job hoàn thành hay bị block, JobTracker sẽ lấy job khác trong list này (FIFO) ra thực hiện
- ❖ JobTracker có một job scheduler với nhiệm vụ lấy vị trí các split (từ HDFS do chương trình client tạo) và sau đó tạo một danh sách các task để thực thi
- ❖ Mỗi split có một maptask để thực thi => số lượng maptask bằng với số lượng split
- ❖ JobTracker lưu trữ thông tin trạng thái và tiến độ của tất cả các task

Liên lạc giữa JobTracker và TaskTracker



- ❖ Hadoop cung cấp cho các TaskTracker cơ chế gửi heartbeat đến JobTracker theo chu kỳ thời gian
- ❖ Thông tin bên trong heartbeat này cho phép JobTrack biết được TaskTracker này có thể thực thi task hay không
 - ❖ Tasktracker có thể cùng lúc chạy nhiều map task và reduce task một cách đồng bộ
 - ❖ Số lượng tối đa các task chạy cùng lúc dựa trên số lượng core, số lượng bộ nhớ Ram và kích thước heap (bộ nhớ cần để thực thi một maptask) bên trong TaskTracker
- ❖ 2 loại TaskTracker: TaskTracker thực thi maptask, TaskTracker thực thi reduce task

Làm việc ở MapTaskTracker

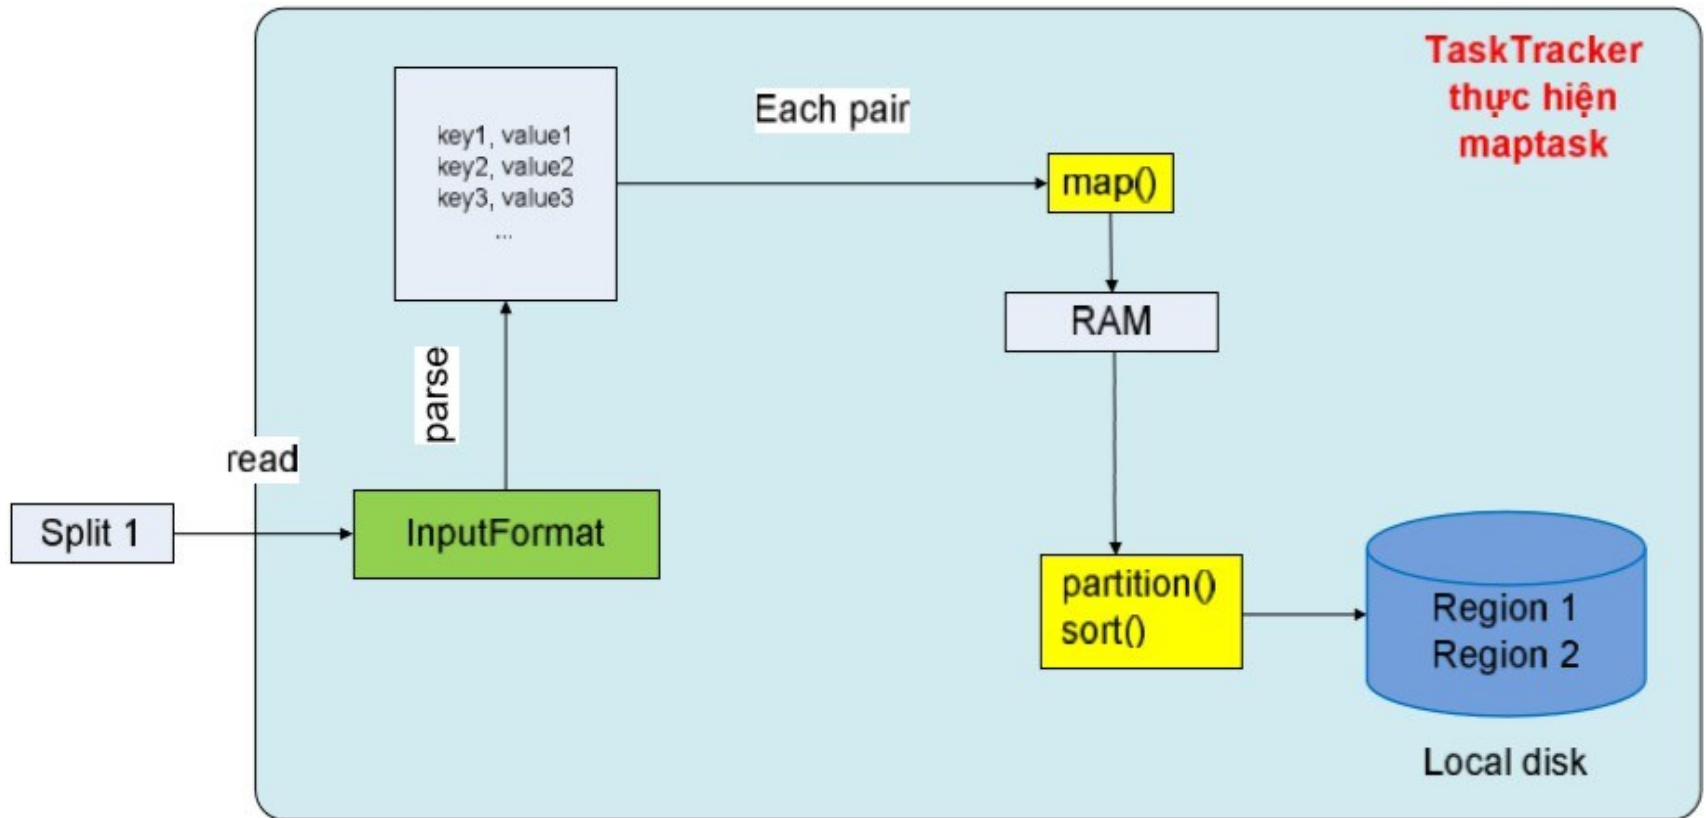
- ❖ TaskTracker nhận thực thi maptask, kèm theo là vị trí của input split trên HDFS
- ❖ MapTaskTracker nạp dữ liệu của split từ HDFS vào bộ nhớ
- ❖ Dựa vào kiểu format của dữ liệu input do client chọn, MapTaskTracker phân tích split này để phát sinh ra tập các record
 - ❖ Record này có 2 trường: key và value
 - ❖ Ví dụ: với kiểu input format là text, record ứng với mỗi dòng: key là offset đầu tiên của dòng (offset toàn cục), value là chuỗi ký tự của dòng

Làm việc ở MapTaskTracker

- ❖ Với tập các record này, MapTaskTracker chạy vòng lặp để lấy từng record làm input cho hàm **map** để trả về output là dữ liệu gồm key và value trung gian (intermediate)
- ❖ Dữ liệu output của hàm map được chia thành các mảnh dữ liệu trung gian (dựa trên hàm partition)
- ❖ Mỗi mảnh dữ liệu trung gian được sắp xếp theo key trung gian (dựa trên hàm sort) và lưu thành các vùng tương ứng (partition) trên đĩa cục bộ của MapTaskTracker
- ❖ Cuối cùng, MapTaskTracker sẽ gửi trạng thái completed của maptask và danh sách các vị trí của các partition (region) output trên localdisk của nó đến JobTracker
- ❖ Lưu ý: Từng partition này sẽ ứng với dữ liệu input của reduce task sau này

Làm việc ở MapTaskTracker

- ❖ MapTaskTracker thực hiện maptask



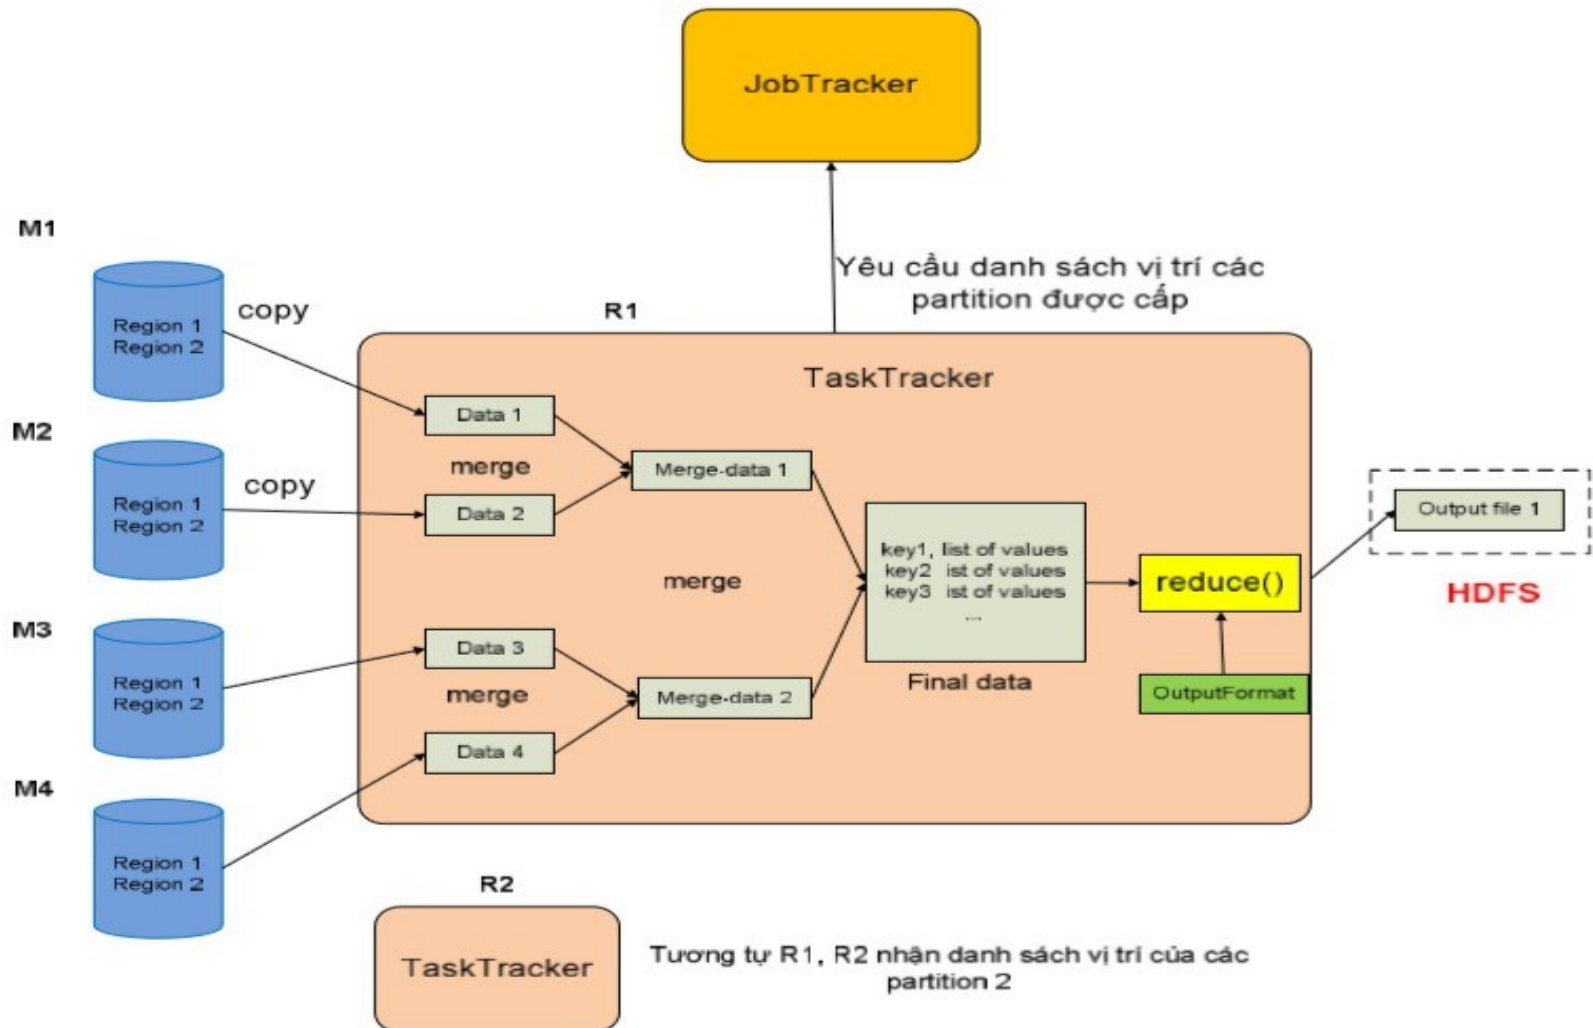
Làm việc ở ReduceTaskTracker

- ❖ Input của một ReduceTaskTracker là một region cụ thể cùng danh sách các vị trí lưu dữ liệu của region này trên localdisk của các MapTaskTracker
- ❖ Sau khi MapTaskTracker cuối cùng hoàn thành nhiệm vụ, ReduceTaskTracker sẽ nhận được đầy đủ thông tin các vị trí lưu dữ liệu của region mà JobTracker giao cho
- ❖ Với danh sách vị trí này, ReduceTaskTracker nạp (copy) dữ liệu từ các vị trí này và thực hiện việc hợp dữ liệu theo key trung gian
 - ❖ Quá trình nạp và hợp dữ liệu có thể chạy song song để tăng hiệu suất làm việc
 - ❖ Kết quả thu được danh sách các cặp (keyInt,list(valInt))
- ❖ TaskTracker chạy vòng lặp để lấy từng record ra làm input cho hàm reduce

Làm việc ở ReduceTaskTracker

- ❖ Hàm reduce dựa vào kiểu format của output để thực hiện và trả ra kết quả output thích hợp
- ❖ Tất cả các dữ liệu output này sẽ được lưu vào một file và file này sau đó sẽ được ghi xuống HDFS
- ❖ Khi ReduceTaskTracker thực hiện thành công reduce task, thì nó sẽ gửi thông báo trạng thái “completed” của reduce task được phân công đến JobTracker
- ❖ Nếu reduce task này là task cuối cùng của job thì JobTracker
 - ❖ Trả về cho chương trình người dùng biết job này đã hoàn thành
 - ❖ Làm sạch cấu trúc dữ liệu của mình mà dùng cho job này
 - ❖ Thông báo cho các TaskTracker xóa tất cả các dữ liệu output của các map task

Làm việc ở ReduceTaskTracker



Ứng dụng của MapReduce

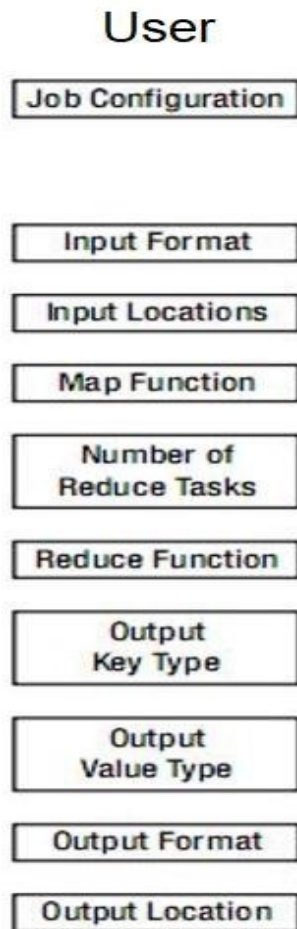
- ❖ MapReduce không phải là mô hình áp dụng được cho mọi vấn đề
- ❖ MapReduce áp dụng tốt cho các trường hợp cần xử lý một khối dữ liệu lớn bằng cách chia ra thành các mảnh nhỏ hơn và xử lý song song
- ❖ Một số trường hợp thích hợp với MapReduce:
 - ❖ Dữ liệu cần xử lý lớn, kích thước tập tin lớn
 - ❖ Các ứng dụng thực hiện xử lý, phân tích dữ liệu, thời gian xử lý đáng kể, có thể tính bằng phút, giờ, ngày, tháng..
 - ❖ Cần tối ưu hoá về băng thông trên cluster
- ❖ Một số trường hợp có thể không phù hợp:
 - ❖ Dữ liệu cần xử lý là tập hợp nhiều tập tin nhỏ
 - ❖ Cần tìm kiếm nhanh (tốc độ có ý nghĩa đến từng giây) trên tập dữ liệu lớn. Do độ trễ khi xử lý các MapReduce Job và khởi tạo các task trên DataNode

Môi trường lập trình MapReduce

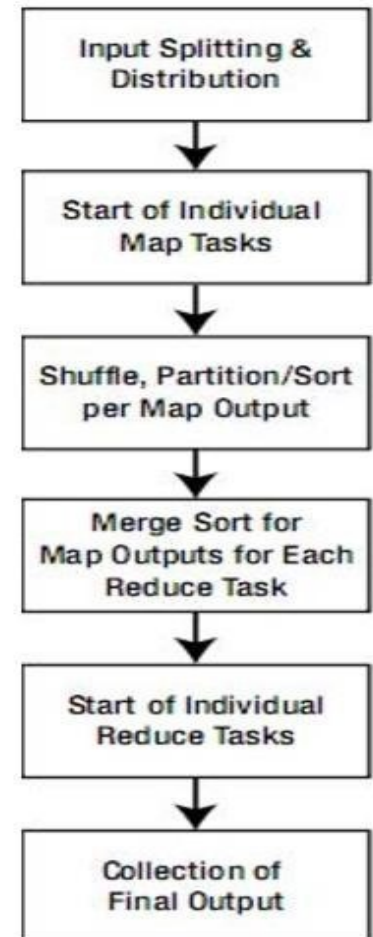
- ❖ Phân chia nhiệm vụ
- ❖ Các kiểu dữ liệu Hadoop hỗ trợ
- ❖ Lớp Mapper
- ❖ Lớp Reducer
- ❖ Hadoop I/O

Phân chia nhiệm vụ

❖ Giữa người dùng và framework Hadoop



Hadoop Framework



Người dùng

- ❖ Thiết lập thông số cấu hình hệ thống của MapReduce Job
- ❖ Định nghĩa hàm map, reduce
- ❖ Có thể thiết lập thông tin số lượng reduce task (mặc định do
 - hệ thống thiết lập)
- ❖ Truyền vào:
 - ❖ Kiểu format, đường dẫn của dữ liệu input
 - ❖ Kiểu format cho từng record (key, value) của dữ liệu output của hàm reduce
 - ❖ Kiểu format cho dữ liệu output cuối cùng, vị trí mà file output sẽ lưu

Framework Hadoop

- ❖ Với thông tin cấu hình, hệ thống thực hiện:
 - ❖ Kiểm tra các thông tin này liệu có hợp lệ hay không
 - ❖ Thông báo người dùng là ứng dụng có thể bắt đầu (nếu thông tin hợp lệ)
- ❖ Dựa vào 2 thông tin về kiểu format (format đọc dữ liệu và format từng record input) và đường dẫn dữ liệu input
 - ❖ Hệ thống tính toán và thực hiện việc chia nhỏ dữ liệu input này thành các input split
- ❖ Sau khi có tập dữ liệu input split, hệ thống phân tán map task trên các TaskTracker thực hiện
- ❖ Thực hiện hàm map trả về từng record với format như người dùng định nghĩa

Framework Hadoop

- ❖ Với tập record đầu ra hàm map, hệ thống thực hiện
 - ❖ Phân chia chúng vào từng vào từng partition (số lượng partition đúng bằng số lượng reduce task)
 - ❖ Sắp xếp theo khóa trong từng partition
- ❖ Sau khi tất cả maptask hoàn thành, hệ thống thực hiện
 - ❖ Lấy dữ liệu của một partition trên các output của maptask
 - ❖ Trộn các dữ liệu này lại và sắp xếp để cho ra tập các record (key, danh sách value)
 - ❖ Xử lý các record bằng việc chạy hàm reduce task
- ❖ Reduce task trả về từng record với kiểu format output cuối cùng đã được người dùng định nghĩa trước
- ❖ Reduce task sẽ lưu dữ liệu output đường dẫn của mà file đầu ra đã được người dùng định nghĩa trước

Các kiểu dữ liệu Hadoop hỗ trợ

- ❖ BooleanWritable: Lớp bao (wrapper) của biến kiểu Boolean chuẩn
- ❖ ByteWritable: Lớp bao của biến kiểu byte đơn
- ❖ DoubleWritable: Lớp bao của biến kiểu Double
- ❖ FloatWritable: Lớp bao của biến kiểu Float
- ❖ IntWritable: Lớp bao của biến kiểu Integer
- ❖ LongWritable: Lớp bao của biến kiểu Long
- ❖ Text: Lớp bao của biến kiểu văn bản định dạng UTF-8
- ❖ NullWritable: Lớp để giữ chỗ khi mà key hoặc value không cần thiết

Lớp Mapper

- ❖ Là lớp liên quan đến cài đặt hàm map
- ❖ Cài đặt từ interface Mapper và kế thừa từ lớp MapReduceBase
- ❖ Lớp MapReduceBase
 - ❖ Là lớp cơ sở cho cả mapper và reducer
 - ❖ Bao gồm hai phương thức hoạt động hiệu quả
 - ❖ `void configure(JobConf job)`: Trong hàm này, người dùng có thể trích xuất các thông số cài đặt từ biến job. Hàm này được gọi trước khi xử lý dữ liệu
 - ❖ `void close()` - Như hành động cuối trước khi chấm dứt nhiệm vụ map, hàm này nên được gọi bất cứ khi nào kết thúc: kết nối cơ sở dữ liệu, các file đang mở

Lớp Mapper

- ❖ Sử dụng mẫu Mapper<K1, V1, K2, V2>
 - ❖ K1, V1: Kiểu dữ liệu tương ứng của key, value đầu vào
 - ❖ K2, V2: Kiểu dữ liệu tương ứng của key, value trung gian
- ❖ Sử dụng phương thức map duy nhất để xử lý các cặp (key/value) như sau:
 - ❖ `void map(K1 key, V1 value, OutputCollector<K2, V2> output, Reporter reporter) throws IOException`
 - ❖ Tạo ra một danh sách **output** (có thể rỗng) các cặp (K2, V2) từ một cặp đầu vào (K1, V1)
 - ❖ Nội dung hàm cài đặt quá trình mapping dữ liệu đầu vào thành dữ liệu trung gian
 - ❖ Reporter cung cấp các tùy chọn để ghi lại thông tin thêm về mapper như tiến triển công việc

Lớp Reducer

- ❖ Là lớp liên quan đến cài đặt hàm reduce
- ❖ Mở rộng từ lớp MapReduceBase để cho phép cấu hình và dọn dẹp
- ❖ Thực hiện ngầm: Sắp xếp và nhóm các giá trị trung gian theo các key trung gian để tạo ra danh sách các cặp (K2 key, Iterator<V2> values) phục vụ cho hàm reduce
- ❖ Sử dụng phương thức reduce duy nhất như sau
 - ❖ `void reduce(K2 key, Iterator<V2> values, OutputCollector<K3,V3> output, Reporter reporter) throws IOException`
 - ❖ Nội dung hàm cài đặt quá trình reducing dữ liệu trung gian thành dữ liệu đầu ra cuối cùng
 - ❖ Sinh ra một danh sách (có thể rỗng) các cặp (K3, V3)

Hadoop I/O

- ❖ Dữ liệu đầu vào thường là các tập tin lớn, có thể đến hàng chục hoặc hàng trăm gigabyte và cũng có thể nhiều hơn
- ❖ Một trong những nguyên tắc cơ bản của xử lý MapReduce là sự phân tách dữ liệu đầu vào thành các khối (chunks)
- ❖ MapReduce có thể xử lý các khối này một cách song song sử dụng nhiều máy tính khác nhau
- ❖ Trong Hadoop thuật ngữ “khối” này được gọi là “input splits”
- ❖ Việc quản lý truy cập và phân chia các khối được thực hiện
 - bởi hệ thống file HDFS của Hadoop
- ❖ Định dạng file mà HDFS hỗ trợ:
 - ❖ InputFormat
 - ❖ OutputFormat

InputFormat

- ❖ Mỗi record mô tả của một cặp key/value
- ❖ TextInputFormat
 - ❖ Key: LongWritable, Value: Text
 - ❖ Mỗi dòng trong file text là một record
 - ❖ Key là một byte offset của dòng, Value là nội dung của dòng đó
- ❖ KeyValueTextInputFormat:
 - ❖ Key: LongWritable, Value: Text
 - ❖ Mỗi dòng trong file text là một record. Ký tự phân chia đầu tiên trên mỗi dòng
 - ❖ Tất cả mọi thứ đứng trước ký tự phân chia là key và đứng sau là value
 - ❖ Ký tự phân chia (mặc định là dấu tab (\t)) được thiết lập bởi thuộc tính `key.value.separator.input.line` với lệnh:
`conf.set("key.value.separator.in.input.line", ",");`

Ví dụ InputFormat

- ❖ TextInputFormat phù hợp các tập tin đầu vào có dữ liệu đơn giản, không cấu trúc như file văn bản chỉ chứa từ (bài toán đếm từ)
- ❖ KeyValueTextInputFormat được sử dụng trong các tập tin đầu vào có cấu trúc hơn

- ❖ 17:16:18

- <http://hadoop.apache.org/core/docs/r0.19.0/api/index.html> 17:16:19

- http://hadoop.apache.org/core/docs/r0.19.0/mapred_tutorial.html

- 17:16:20

- <http://wiki.apache.org/hadoop/GettingStartedWithHadoop> 17:16:20

- http://www.maxim.com/hotties/2008/finalist_gallery.aspx

- 17:16:25 <http://wiki.apache.org/hadoop/>

InputFormat

- ❖ `SequenceFileInputFormat<K,V>`:
 - ❖ Để đọc các file tuần tự (sequence files)
 - ❖ Key và value được người sử dụng định nghĩa
 - ❖ Sequence file là một dạng file nhị phân nén đặc biệt của hadoop
 - ❖ Nó tối ưu cho truyền dữ liệu giữa đầu ra của một MapReduce job tới đầu vào của một MapReduce job khác.
- ❖ `NlineInputFormat`:
 - ❖ Giống như `TextInputFormat`, nhưng mỗi split được đảm bảo phải có chính xác N dòng.
 - ❖ Thuộc tính `mapred.line.input.format.linespermap` (mặc định là 1) để thiết lập N
 - ❖ Key: `LongWritable`, Value: `Text`

OutputFormat

- ❖ Dữ liệu đầu ra của MapReduce lưu vào trong các file sử dụng lớp `OutputFormat`, tương tự lớp `InputFormat`
- ❖ Các định dạng đầu ra: `TextOutputFormat`, `KeyValueTextOutputFormat`, `SequenceFileOutputFormat`
- ❖ Sử dụng lệnh `setOutputFormat` để thiết lập định dạng đầu ra
- ❖ Đầu ra thì không split, mỗi reducer ghi một output riêng
- ❖ Sử dụng lệnh `setOutputPath` thiết lập thư mục đầu ra
- ❖ Các tập tin đầu ra nằm trong thư mục đầu ra và tên là `part-nnnnn`, với `nnnnn` là ID vùng của reducer

Lập trình bài toán Word Count

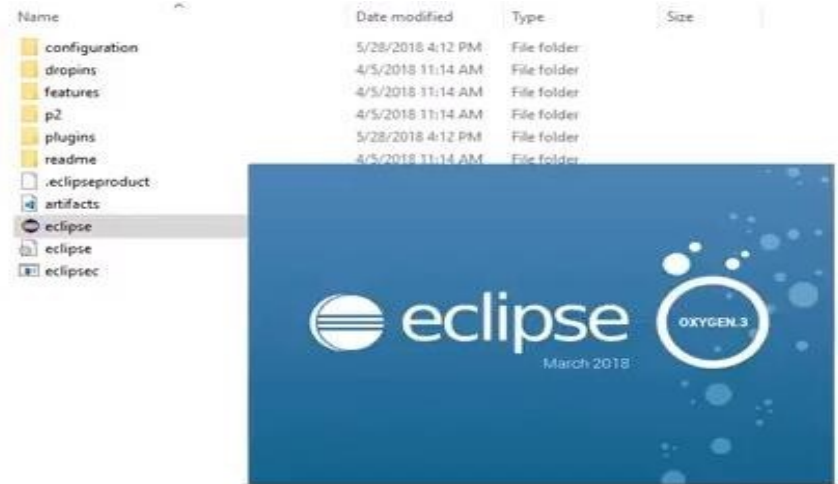
- ❖ Mô tả bài toán Word Count
- ❖ Khởi tạo project MapReduce
- ❖ Các nhiệm vụ chính
- ❖ Mã nguồn lớp WordCountDriver
- ❖ Mã nguồn lớp WordCountMapper
- ❖ Mã nguồn lớp WordCountReducer

Mô tả bài toán Word Count


- ❖ Input: File input.txt có nội dung:
 - ❖ Bus, Car, bus, car, train, car, bus, car, train, bus, TRAIN, BUS, buS, caR, CAR, car, BUS, TRAIN
- ❖ Output: File text có nội dung:
 - ❖ BUS 2
 - ❖ Bus 1
 - ❖ CAR 1
 - ❖ Car 1
 - ❖ TRAIN 2
 - ❖ buS 1
 - ❖ bus 3
 - ❖ caR 1
 - ❖ car 4
 - ❖ train 2

Khởi tạo project MapReduce

- ❖ B1: Vào thư mục eclipse, click đúp file ứng dụng eclipse để khởi động eclipse và đợi

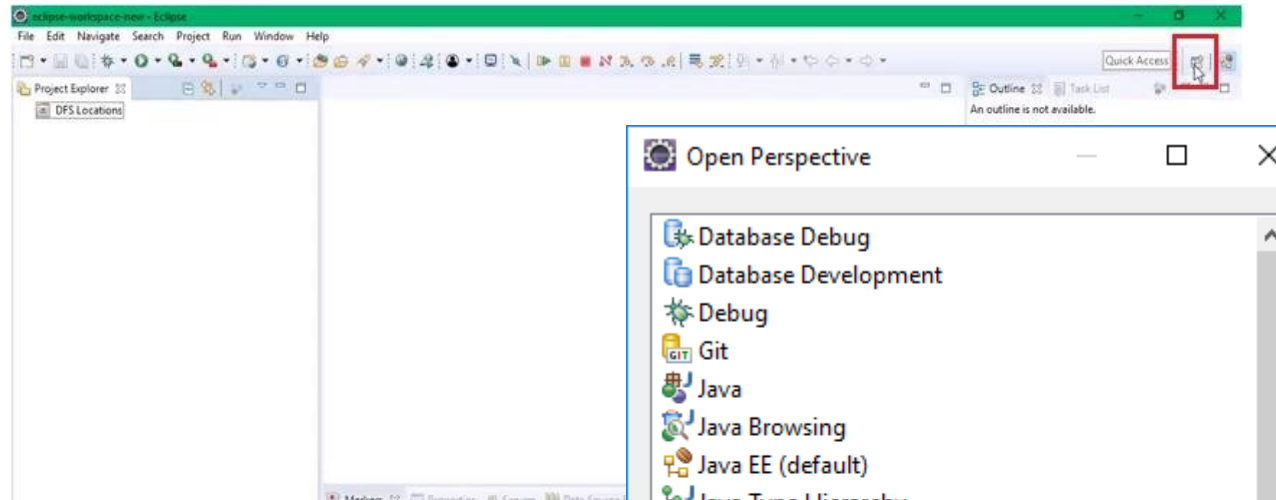


- ❖ B2: Chọn thư mục workspace và nhấn nút Launch



Khởi tạo project MapReduce

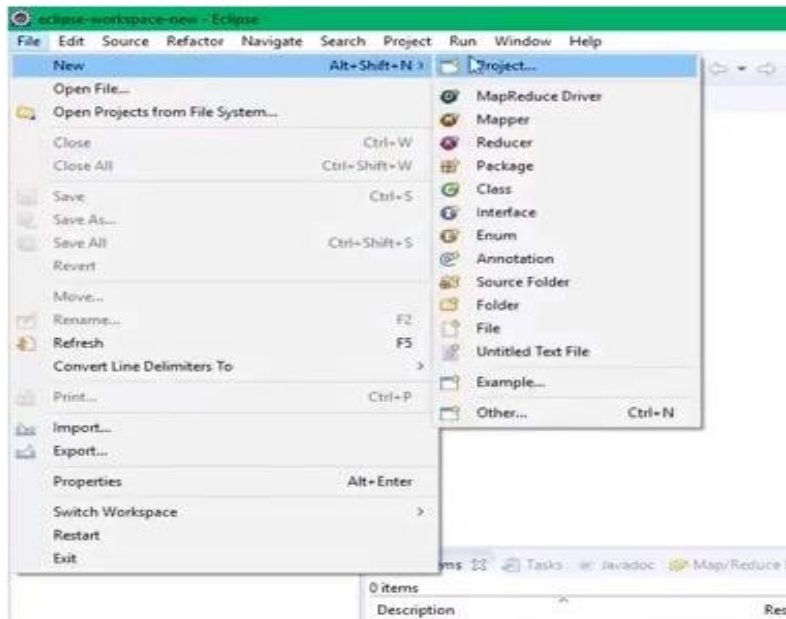
- ❖ B3: Nhấn nút “Open perspective” để mở hộp thoại “Open perspective”



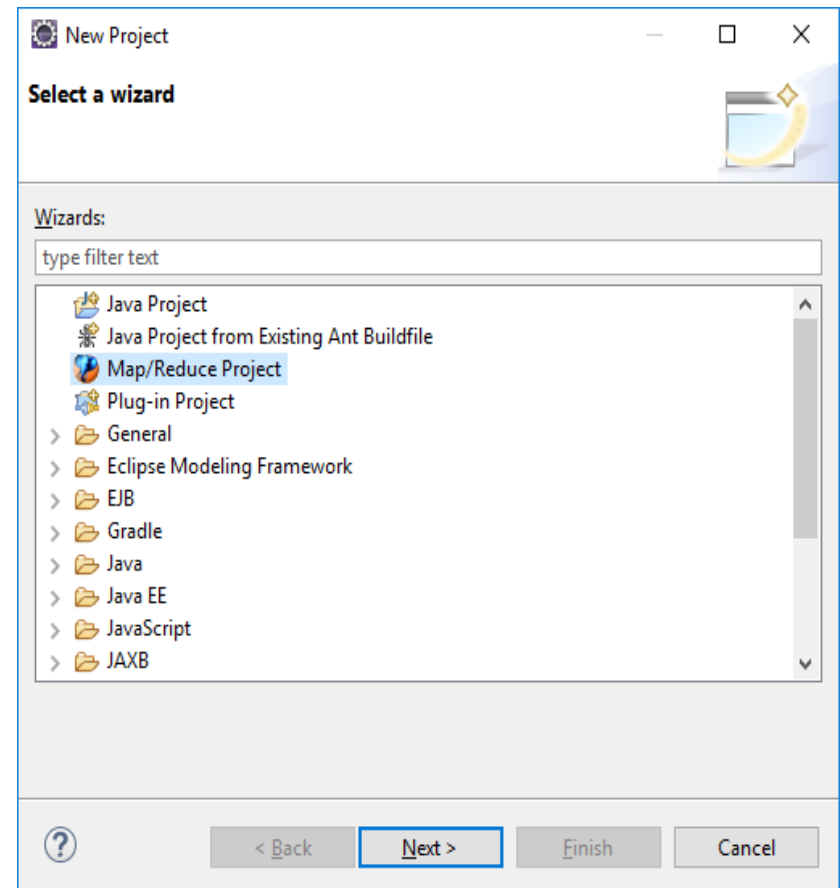
- ❖ B4: Chọn “Map/Reduce”, nhấn Open

Khởi tạo project MapReduce

- ❖ B5: Tạo project Map/Reduce: Vào File->New->Project

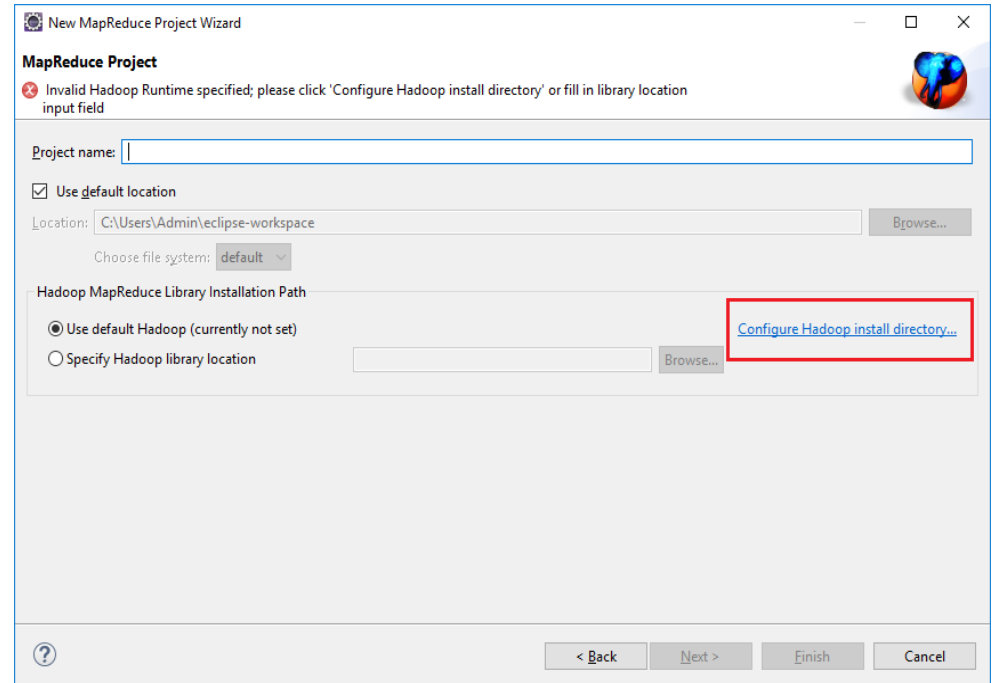


- ❖ B6: Trong cửa sổ “New Project”, chọn Map/ReduceProject và nhấn Next



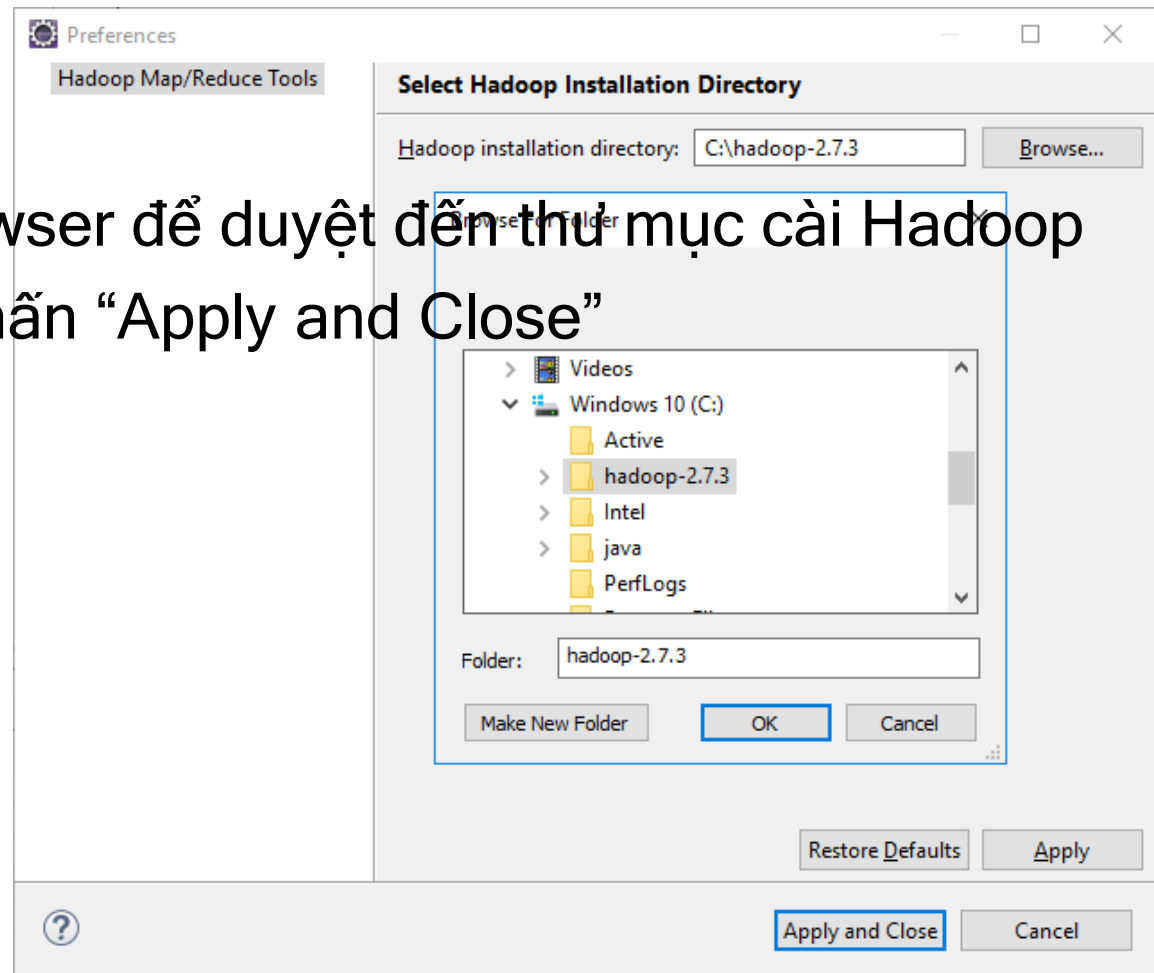
Khởi tạo project MapReduce

- ❖ B7: Nhấn vào link “Configure Hadoop install directory”



Khởi tạo project MapReduce

- ❖ B8: Nhấn nút Browser để duyệt đến thư mục cài Hadoop
- ❖ B9: Nhấn nút Browser để duyệt đến thư mục cài Hadoop
- ❖ B10: Nhấn OK, nhấn “Apply and Close”



Khởi tạo project MapReduce

- ❖ B11: Gõ tên project vào hộp Textbox “Project name” và nhấn Finish

New MapReduce Project Wizard

MapReduce Project
Create a MapReduce project.

Project name:

☒ Use default location
Location: [Browse...](#)
Choose file system: [default](#)

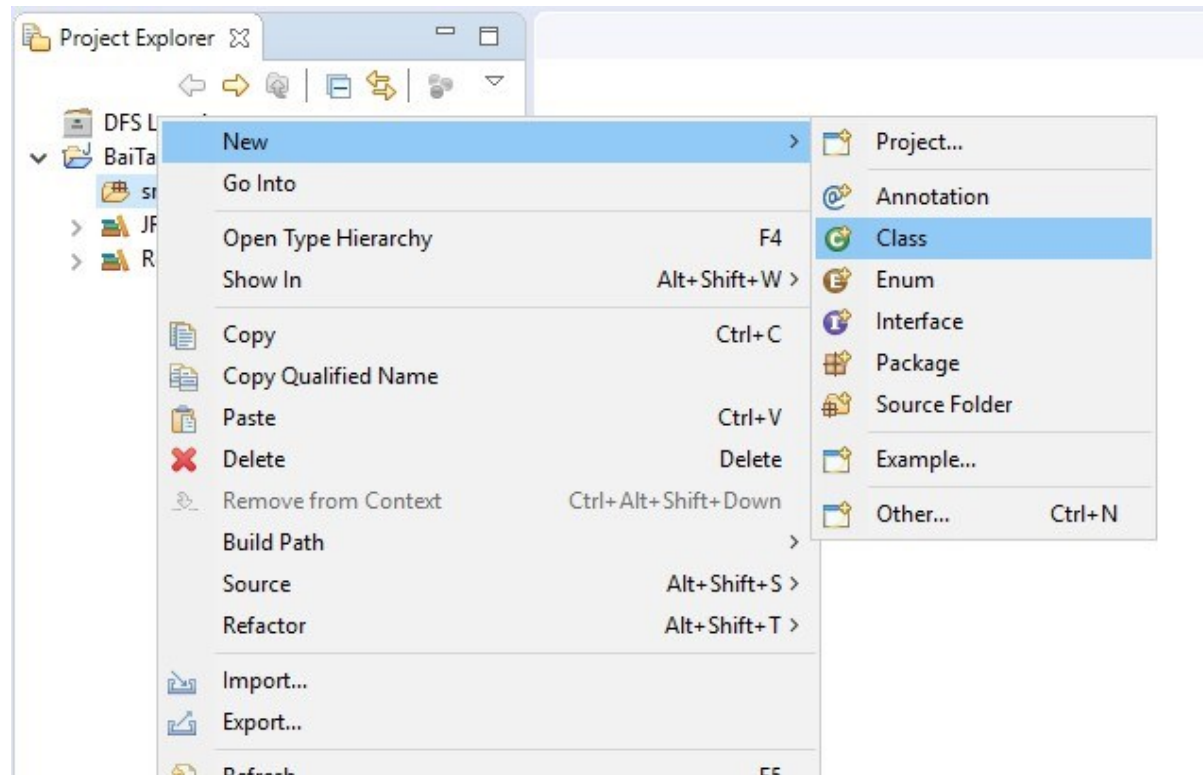
Hadoop MapReduce Library Installation Path

☒ Use default Hadoop [Configure Hadoop install directory...](#)
☐ Specify Hadoop library location [Browse...](#)

[?](#) [< Back](#) [Next >](#) [Finish](#) [Cancel](#)

Tạo file java trong project MapReduce

- ❖ B1: Chuột phải vào mục src trong mục project, chọn New->Class để mở hộp thoại “New Java Class”



Tạo file java trong project MapReduce

- ❖ B2: Gõ tên file vào hộp Textbox Name và Enter

New Java Class

Java Class

The use of the default package is discouraged.

Source folder: BaiTap1/src Browse...

Package: (default) Browse...

☐ Enclosing type: Browse...

Name: WordCount

Modifiers: ☒ public ☐ package ☐ private ☐ protected
☐ abstract ☐ final ☐ static

Superclass: java.lang.Object Browse...

Interfaces: Add... Remove

Which method stubs would you like to create?

☐ public static void main(String[] args)
☐ Constructors from superclass
☒ Inherited abstract methods

Do you want to add comments? (Configure templates and default value [here](#))
☐ Generate comments

Finish Cancel

Các nhiệm vụ chính

- ❖ Định nghĩa lớp Driver: bao gồm hàm main
 - ❖ Thông tin vào ra
 - ❖ Thông tin cấu hình Job
 - ❖ Khởi tạo Job
- ❖ Định nghĩa lớp Mapper: chứa hàm map
- ❖ Định nghĩa lớp Reducer: chứa hàm reduce

Mã nguồn lớp Driver

- ❖ Xem file WordCount1Driver.java
- ❖ Tạo file

Mã nguồn lớp Mapper

- ❖ Xem file WordCount1Mapper.java

Mã nguồn lớp Reducer

❖ Xem file WordCount1Reducer.java