Phân tích dữ liệu lớn



MapReduce - Lập trình chương trình WordCount

Apr 24, 2022

I. Thử nghiêm với hàm mẫu WordCount của Hadoop

Trong thư mục **C:\hadoop-3.3.0\share\hadoop\mapreduce** Hadoop đã có sẵn chương trình MapReduce **hadoop-mapreduce-examples-3.3.0.jar**. Ta sẽ thử nghiệm bài toán đếm từ bằng cách tạo ra file text chứa dữ liệu và đầu ra mong muốn là các cặp **[từ: số lượng xuất hiện]**

Bước 1: Tao file data.txt

Nội dung của file data.txt là:

Bus Car bus
car train car
bus car train
bus TRAIN BUS
buS caR CAR
car BUS TRAIN

Bước 2: Tạo thư mục input tại hdfs và lưu file data.txt

Tạo thư mục **input** trong hdfs với câu lệnh:

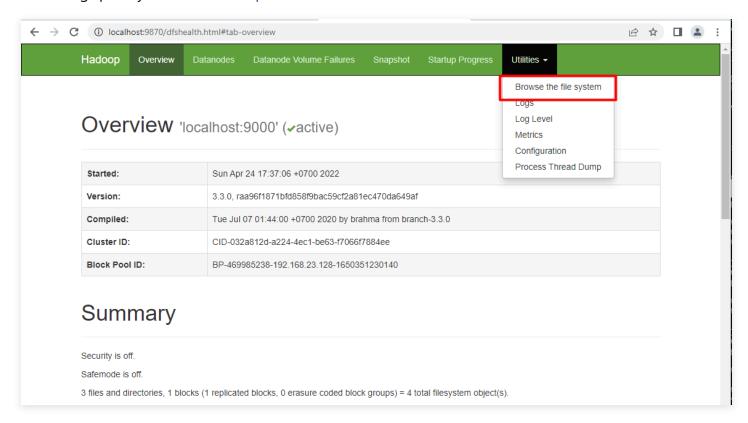
hdfs dfs -mkdir /input

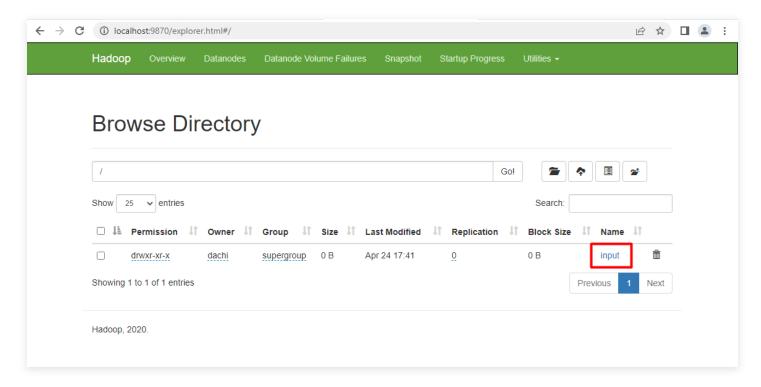
Đẩy file data.txt vào folder input vừa tạo:

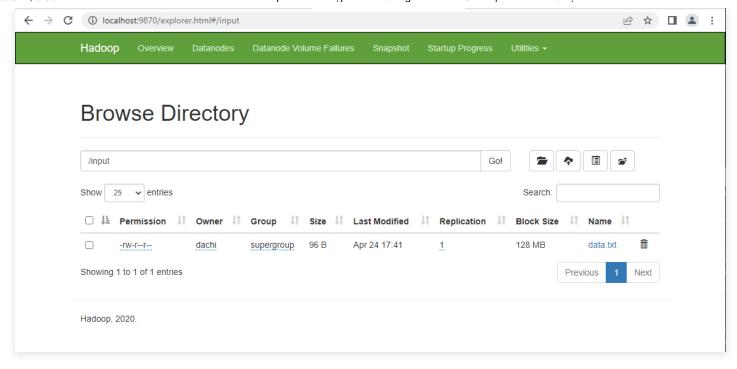
hdfs dfs -put "C:\input\data.txt" /input

Lưu ý: Thay "C:\input\data.txt" bằng nơi lưu trữ file trong máy

Vào trang quản lý NameNode http://localhost:9870/ để kiểm tra file







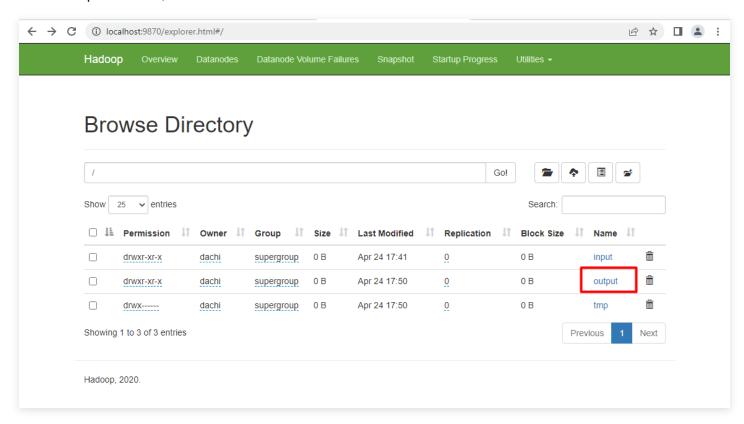
Bước 3: Chạy chương trình MapReduce và xem kết quả

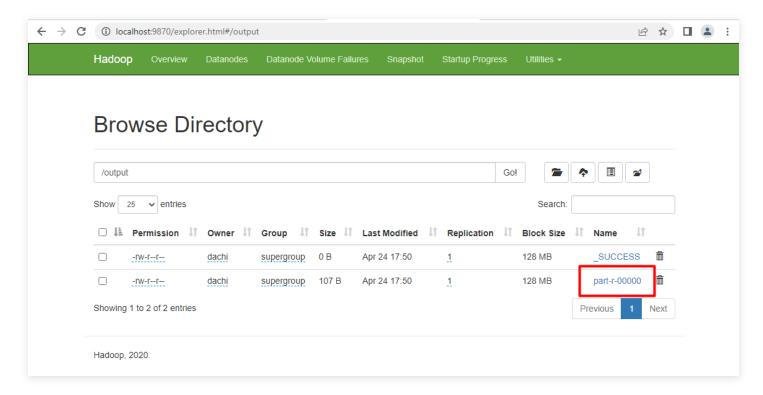
Chương trình mẫu MapReduce của Hadoop nằm tại C:\hadoop-

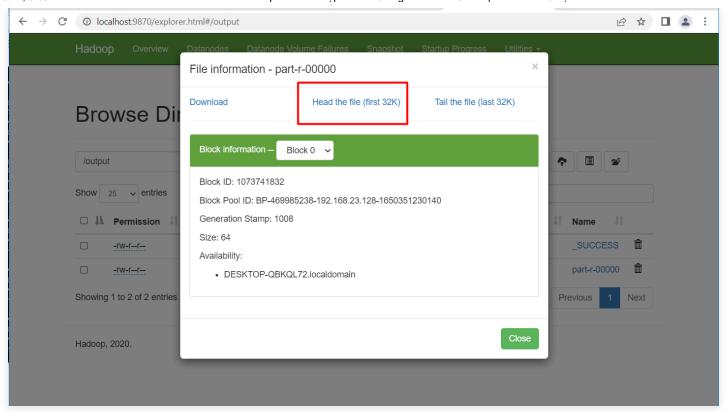
3.3.0\share\hadoop\mapreduce\hadoop-mapreduce-examples-3.3.0.jar. Ta sẽ thử nghiệm đầu vào chương trình là file **data.txt** và kết quả sẽ được lưu tại folder **/output**, lênh thực hiện"

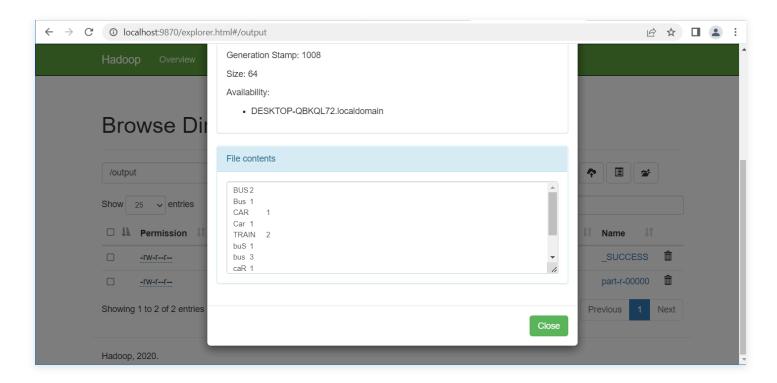
```
hadoop jar "C:\hadoop-3.3.0\share\hadoop\mapreduce\hadoop-mapreduce-examples-3.3.0.jar" wo
 Command Prompt
                                                                                                                   П
                                                                                                                         ×
C:\Users\dachi>hadoop jar "C:\hadoop-3.3.0\share\hadoop\mapreduce\hadoop-mapreduce-examples-3.3.0.jar" wordcount /input/
data.txt /output
2022-04-24 17:50:04,417 INFO client.DefaultNoHARMFailoverProxyProvider: Connecting to ResourceManager at /0.0.0.8032
2022-04-24 17:50:04,990 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/
dachi/.staging/job_1650796630442_0001
2022-04-24 17:50:05,336 INFO input.FileInputFormat: Total input files to process : 1
2022-04-24 17:50:05,448 INFO mapreduce.JobSubmitter: number of splits:1
2022-04-24 17:50:05,595 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1650796630442_0001
2022-04-24 17:50:05,597 INFO mapreduce.JobSubmitter: Executing with tokens: []
2022-04-24 17:50:05,810 INFO conf.Configuration: resource-types.xml not found
2022-04-24 17:50:05,811
                        INFO resource.ResourceUtils: Unable to find 'resource-types.xml'
2022-04-24 17:50:06,323 INFO impl.YarnClientImpl: Submitted application application_1650796630442_0001
2022-04-24 17:50:06,368 INFO mapreduce.Job: The url to track the job: http://DESKTOP-QBKQL72:8088/proxy/application_1650
796630442_0001/
2022-04-24 17:50:06,369 INFO mapreduce.Job: Running job: job_1650796630442_0001
2022-04-24 17:50:15,650 INFO mapreduce.Job: Job job_1650796630442_0001 running in uber mode : false 2022-04-24 17:50:15,651 INFO mapreduce.Job: map 0% reduce 0%
2022-04-24 17:50:15,651 INFO mapreduce.Job:
2022-04-24 17:50:20,779 INFO mapreduce.Job:
                                              map 100% reduce 0%
2022-04-24 17:50:25,855 INFO mapreduce.Job:
                                             map 100% reduce 100%
                                             Job job_1650796630442_0001 completed successfully
2022-04-24 17:50:25,862 INFO mapreduce.Job:
2022-04-24 17:50:25,963 INFO mapreduce.Job:
                                            Counters: 54
        File System Counters
                FILE: Number of bytes read=173
                FILE: Number of bytes written=531069
                FILE: Number of read operations=0
```

Xem kết quả thu được:









Hoặc dùng lệnh cmd:

hdfs dfs -cat /output/part-r-00000

Lưu ý: thay /output/part-r-00000 thành đường dẫn file muốn xem

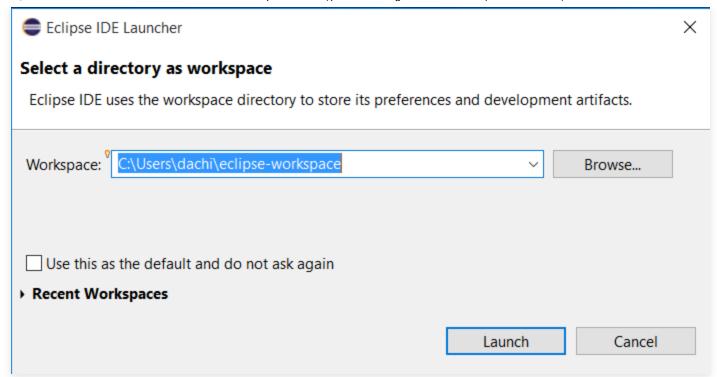
```
Command Prompt
Microsoft Windows [Version 10.0.10240]
(c) 2015 Microsoft Corporation. All rights reserved.
C:\Users\dachi>hdfs dfs -cat /output/part-r-00000
BUS
        2
Bus
        1
CAR
        1
Car
        1
TRAIN
        2
buS
        1
        3
bus
caR
        1
car
        4
train
```

Như vậy ta đã chạy thành công chương trình mẫu MapReduce của Hadoop cung cấp.

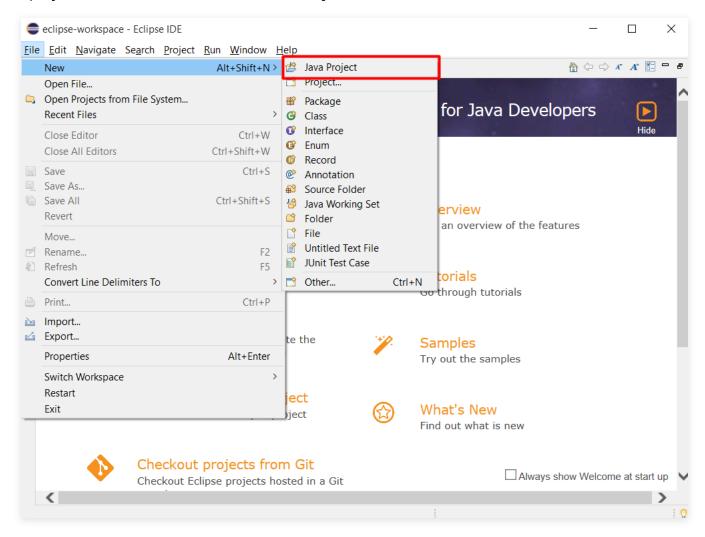
II. Lập trình chương trình WordCount bằng Eclipse

Bước 1: Tạo project

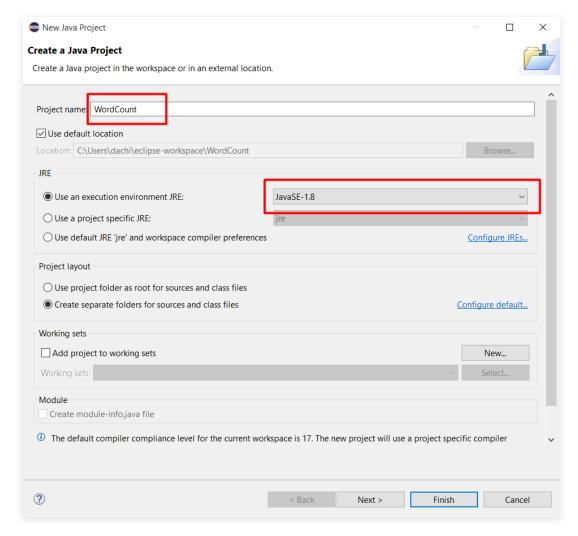
Mở chương trình Eclipse. Chọn **workspace** (nên để mặc định)



Tạo project Java, chọn File > New > Java Project

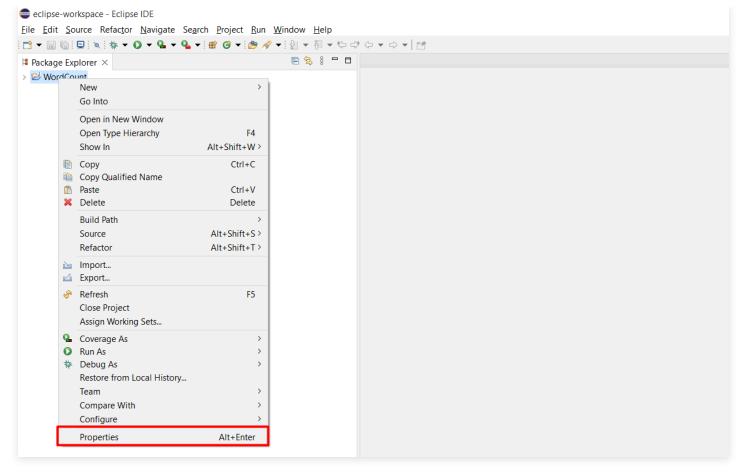


Đặt tên project là WordCount và chọn môi trường là JavaSE-1.8. Xong ấn Finish.

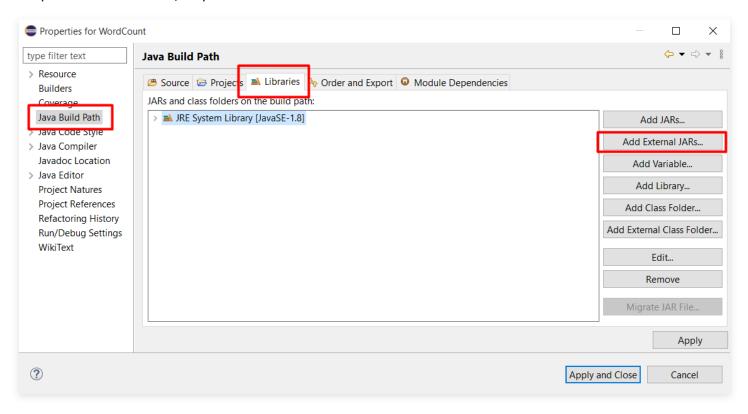


Bước 2: Thêm thư viện cần thiết để chạy MapReduce

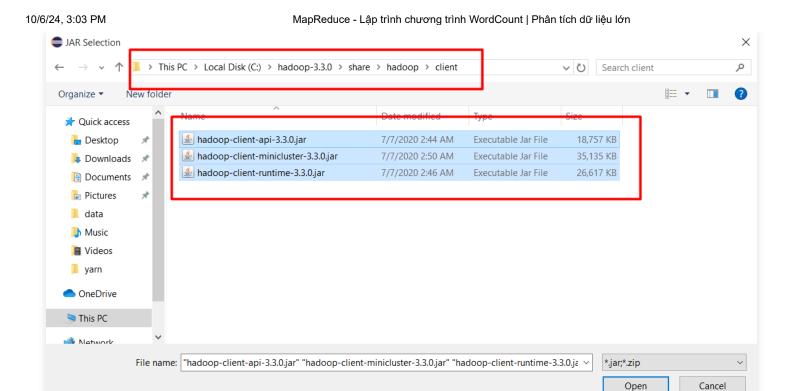
Chuột phải vào project WordCount chọn Properties



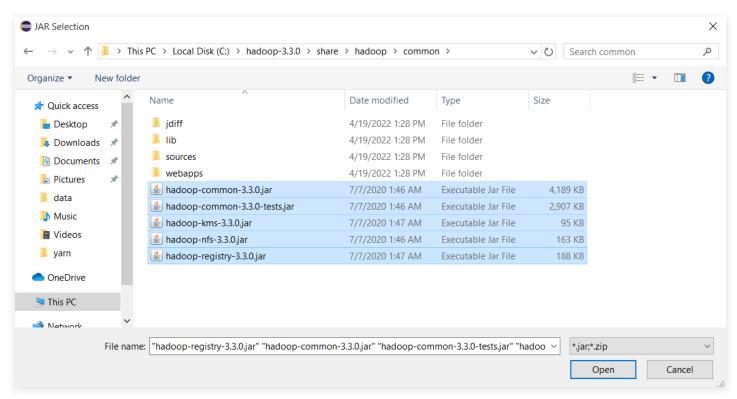
Chọn Java Build Path, chọn tab Libraries và bấm Add External JARs



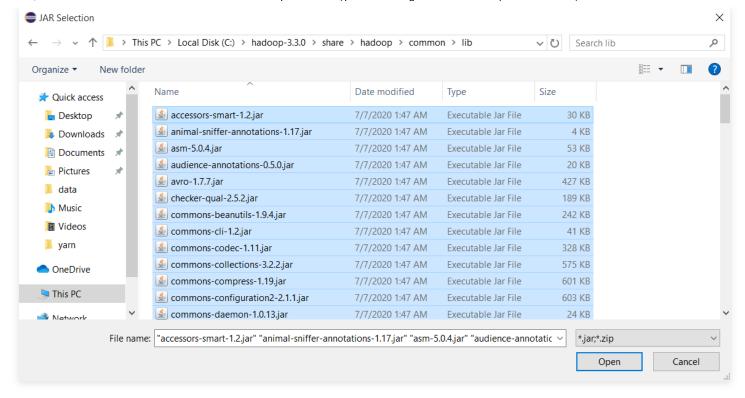
Chọn tất cả file trong thư mục C:\hadoop-3.3.0\share\hadoop\client và ấn Open



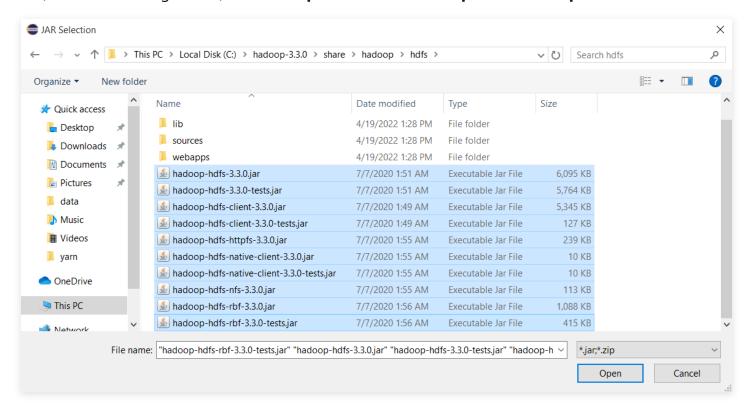
Tương tự chọn tất cả file trong thư mục C:\hadoop-3.3.0\share\hadoop\common và ấn Open



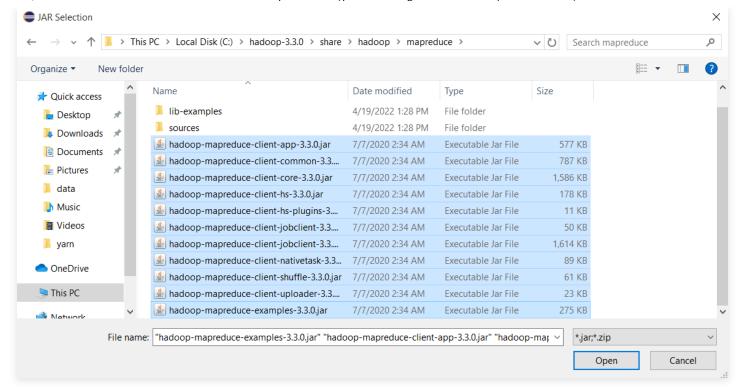
Chọn tất cả file trong thư mục C:\hadoop-3.3.0\share\hadoop\common\lib và ấn Open



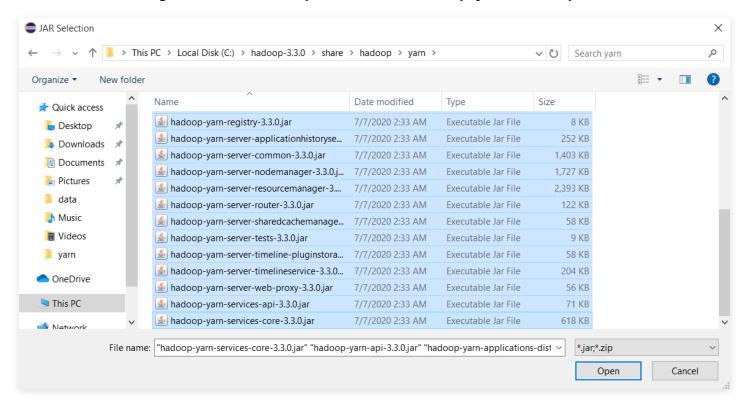
Chọn tất cả file trong thư mục C:\hadoop-3.3.0\share\hadoop\hdfs và ấn Open



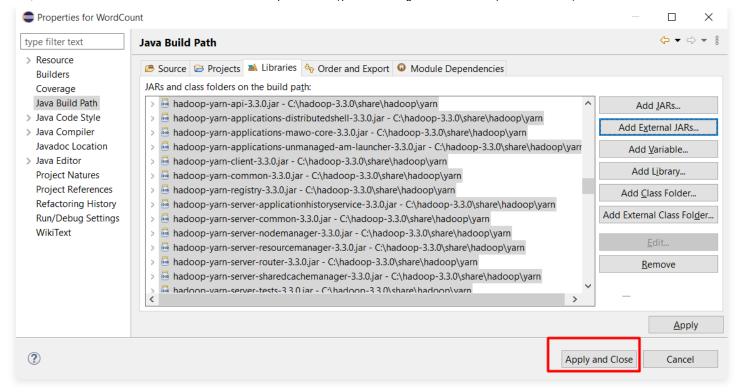
Chọn tất cả file trong thư mục C:\hadoop-3.3.0\share\hadoop\mapreduce và ấn Open



Chọn tất cả file trong thư mục C:\hadoop-3.3.0\share\hadoop\yarn và ấn Open

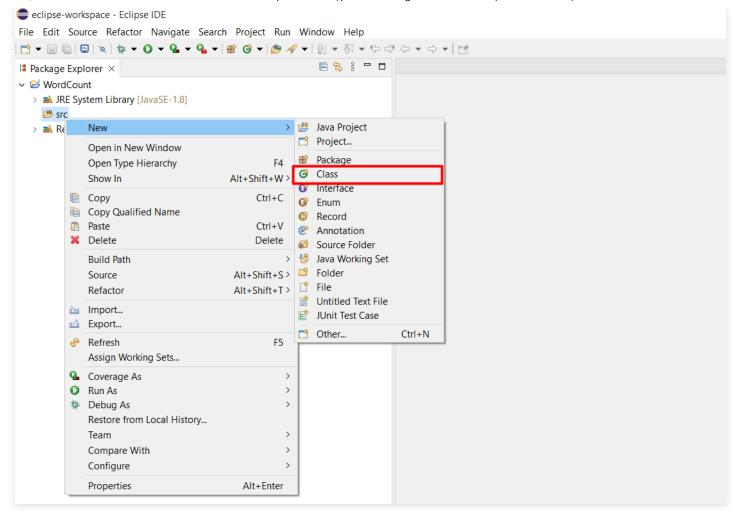


Ấn **Apply and Close**

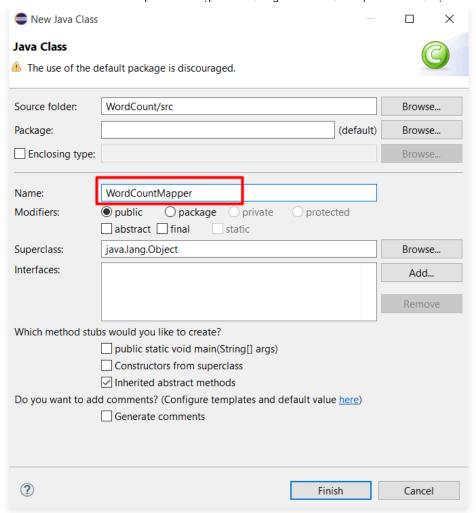


Bước 3: Tạo class xử lý tác vụ MapReduce

Double click vào project WordCount, chuột phải vào src và chọn New > Class



Tạo class để xử lý nhiệm vụ Map, đặt tên là WordCountMapper



Nội dung bên trong file WordCountMapper.java:

```
import java.io.IOException;
import java.util.StringTokenizer;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.io.LongWritable;
public class WordCountMapper extends Mapper <LongWritable, Text, Text, IntWritable>
{
  private Text wordToken = new Text();
  public void map(LongWritable key, Text value, Context context) throws IOException, Inter
  {
    StringTokenizer tokens = new StringTokenizer(value.toString()); //Dividing String into
   while (tokens.hasMoreTokens())
    {
      wordToken.set(tokens.nextToken());
      context.write(wordToken, new IntWritable(1));
```

```
}
}
}
```

Tương tự tạo class xử lý nhiệm vụ **Reduce**, đặt tên là **WordCountReducer**:

```
import java.io.IOException;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Reducer;
public class WordCountReducer extends Reducer <Text, IntWritable, Text, IntWritable>
  private IntWritable count = new IntWritable();
  public void reduce(Text key, Iterable<IntWritable> values, Context context) throws IOExc
  {
    int valueSum = 0;
    for (IntWritable val : values)
      valueSum += val.get();
    }
    count.set(valueSum);
    context.write(key, count);
  }
}
```

Và tạo class **WordCount** chứa hàm **main** để khởi chạy chương trình:

```
import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
import org.apache.hadoop.util.GenericOptionsParser;

public class WordCount
{
    public static void main(String[] args) throws Exception
    {
        Configuration conf = new Configuration();
    }
}
```

```
String[] pathArgs = new GenericOptionsParser(conf, args).getRemainingArgs();
      if (pathArgs.length < 2)</pre>
       {
         System.err.println("MR Project Usage: wordcount <input-path> [...] <output-path>");
         System.exit(2);
      Job wcJob = Job.getInstance(conf, "MapReduce WordCount");
      wcJob.setJarByClass(WordCount.class);
      wcJob.setMapperClass(WordCountMapper.class);
      wcJob.setCombinerClass(WordCountReducer.class);
      wcJob.setReducerClass(WordCountReducer.class);
      wcJob.setOutputKeyClass(Text.class);
      wcJob.setOutputValueClass(IntWritable.class);
      for (int i = 0; i < pathArgs.length - 1; ++i)</pre>
         FileInputFormat.addInputPath(wcJob, new Path(pathArgs[i]));
       }
      FileOutputFormat.setOutputPath(wcJob, new Path(pathArgs[pathArgs.length - 1]));
      System.exit(wcJob.waitForCompletion(true) ? 0 : 1);
    }
 }
🛑 eclipse-workspace - WordCount/src/WordCount.java - Eclipse IDE
File Edit Source Refactor Navigate Search Project Run Window Help
🖹 💲 🖁 🗖 📗 *WordCountMapper.java

□ Package Explorer ×

☑ WordCountReducer.java ☑ *WordCount.java ×
                                                      1 import org.apache.hadoop.conf.Configuration;

    WordCount

                                                       import org.apache.hadoop.fs.Path;
  > Mail JRE System Library [JavaSE-1.8]
                                                       import org.apache.hadoop.io.IntWritable;
 4 import org.apache.hadoop.io.Text;

    # (default package)

                                                      5 import org.apache.hadoop.mapreduce.Job;
       WordCount.java
                                                      6 import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
       WordCountMapper.iava
                                                       import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
       WordCountReducer.java
                                                     8 import org.apache.hadoop.util.GenericOptionsParser;
                                                     10 public class WordCount
                                                     11 {
                                                         public static void main(String[] args) throws Exception
                                                     12⊝
                                                     13
                                                     14
                                                           Configuration conf = new Configuration();
                                                           String[] pathArgs = new GenericOptionsParser(conf, args).getRemainingAr
                                                     16
                                                           if (pathArgs.length < 2)</pre>
```

18

19

20 21

24

System.exit(2);

System.err.println("MR Project Usage: wordcount <input-path> [...] <c

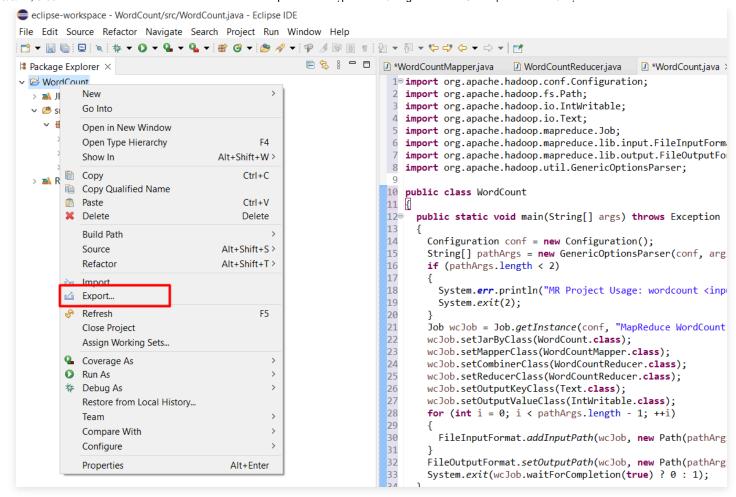
Job wcJob = Job.getInstance(conf, "MapReduce WordCount");

wcJob.setJarByClass(WordCount.class);
wcJob.setMapperClass(WordCountMapper.class);

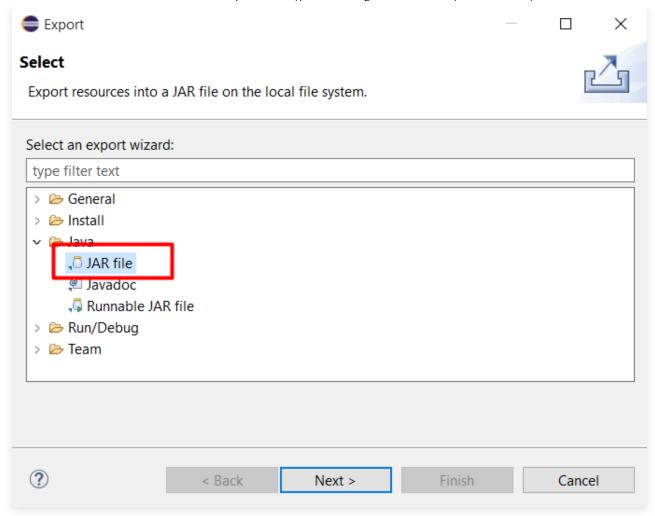
wcJob.setCombinerClass(WordCountReducer.class);
wcJob.setReducerClass(WordCountReducer.class);

Bước 4: Tạo file JAR

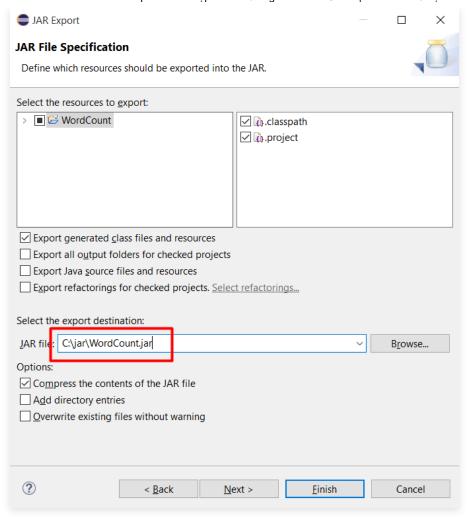
Chuột phải vào project WordCount chọn Export



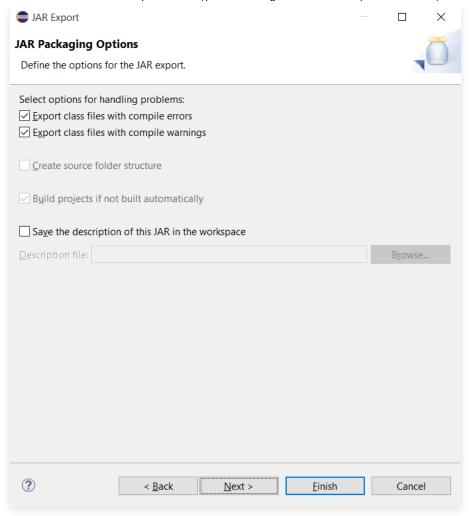
Chon Java > JAR File rồi bấm Next



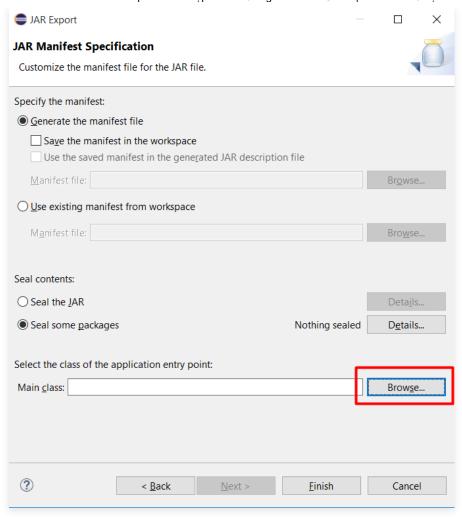
Chọn đường dẫn lưu file JAR và bấm **Next**



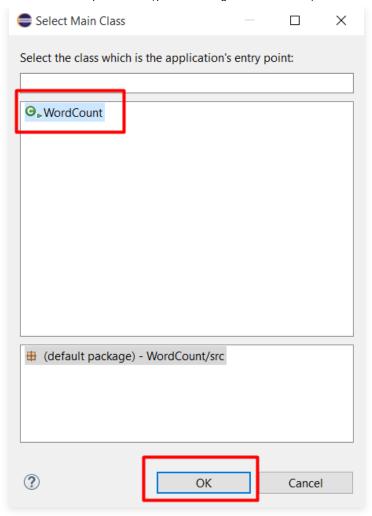
Bấm **Next**



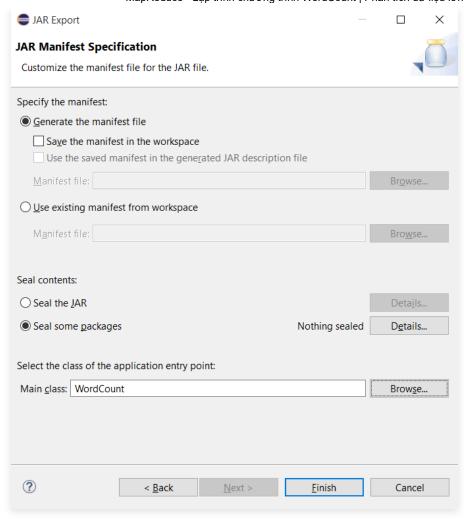
Bấm **Browser** để chọn file **main**



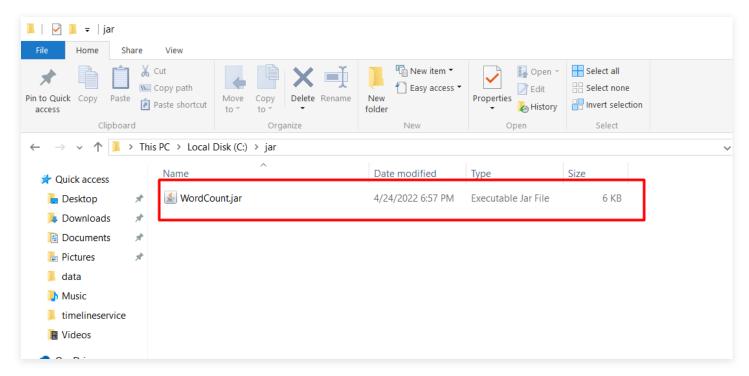
Chọn **WordCount** và bấm **OK**



Bấm **Finish** để thực hiện quá trình **Export**



Vào thư mục chứa lưu file JAR vừa tạo và kiểm tra kết quả



Thử nghiệm trên file dữ liệu **data.txt** đã tạo ở trên, và kết quả thu được lưu tại thư mục **r_output**. Chay lênh sau:

hadoop jar "C:\jar\WordCount.jar" /input/data.txt /r_output

Lưu ý: Thay "C:\jar\WordCount.jar" bằng đường dẫn chứa file JAR ở trên máy

